

نسخه فعلی ریپو را با همان نسخه‌ای که دفعه قبل بررسی کردیم، یعنی حدود **commit 41973b6fdb** در ۲۷ سپتامبر ۲۰۲۶ مقایسه کردم. تغییر اصلی فقط بهینه‌سازی کد نیست؛ پروژه از یک **Daily LSTM experiment** به یک پروژه‌ی دوشاخه‌ی **Daily + Hourly forecasting** تبدیل شده و از نظر طراحی آزمایش هم چند بهبود مهم داشته است.

جمع‌بندی خیلی کوتاه

نسخه قبلی:

۵ سال داده روزانه ← Feature Engineering ← LSTM ← پیش‌بینی قیمت پایانی رسمی جلسه بعد

نسخه جدید:

نسخه روزانه قبلی را حفظ کرده + یک Pipeline مستقل ساعتی ساخته ← داده Intraday واقعی را از معاملات خام تجمیع می‌کند ← Gap ها را کنترل می‌کند ← ویژگی‌های نسبی می‌سازد ← به‌جای قیمت مطلق، **Log Return** را پیش‌بینی می‌کند ← قیمت را بازسازی می‌کند ← روی **A100** آموزش می‌دهد ← نتیجه را با **Persistence / Ridge / OHLCV-LSTM** مقایسه و مستقل **verify** می‌کند.

از نظر مهندسی ML، نسخه جدید به‌طور محسوسی بالغ‌تر است.

۱. بزرگ‌ترین تغییر: Daily → Daily + Hourly

مورد	نسخه قبلی	نسخه جدید
فرکانس اصلی	Daily	Hourly + Daily preserved
داده اصلی	قیمت روزانه TSETMC	معاملات Intraday تجمیع شده به Bar ساعتی
تعداد داده خام	۱,۰۳۸ روز	Bar ۴,۲۷۳ ساعتی
تعداد روز معاملاتی	~۱,۰۳۸	۱,۰۲۵ روز دارای داده ساعتی
Missing/Unresolved	۱ رکورد quarantine	۱۵ روز unresolved
Target	قیمت پایانی رسمی جلسه بعد	Last Traded Price در Bar بعدی

یعنی پروژه دیگر صرفاً روی یک Observation در هر روز کار نمی‌کند.
مثلاً:

2026-09-30 09:00 2026-09-30 10:00 2026-09-30 11:00 2026-09-30 12:00

هر کدام اکنون یک Observation جداگانه‌اند.

۲. Data Acquisition خیلی جدی تر شده

قبلاً داده عمدتاً از خروجی‌های Daily مربوط به pytse-client وارد می‌شد.

نسخه جدید یک exporter مستقل اضافه کرده:

export_foolad_hourly.py

که برای هر روز معاملاتی:

۱ Trade‌های واقعی را دریافت می‌کند.

۲ آن‌ها را Cache می‌کند.

۳ بر اساس ساعت Resample می‌کند.

۴ OHLC + Volume تولید می‌کند.

۵ Coverage هر روز را ثبت می‌کند.

Aggregation تقریباً:

Trades → 1H Bars

با:

• Open

• High

• Low

• Last Price

• Volume

• Returned Trade Count

انجام می‌شود.

۳. یک پیشرفت مهم: Raw Trades واقعاً Verify

می‌شوند

نسخه جدید فقط CSV ساعتی را قبول نمی‌کند.

برای ۱,۰۲۵ فایل معاملات خام، دوباره aggregation را اجرا می‌کند و بررسی می‌کند که:

$$ReconstructedBar = ExportedBar$$

باشد.

یعنی موارد زیر دوباره محاسبه می‌شوند:

Open, High, Low, Last, Volume, TradeCount

و با CSV نهایی مقایسه می‌شوند.

نتیجه فعلی:

تمام ۴,۲۷۳ bar موجود از raw trades بازسازی شده و تطبیق داده شده‌اند.

این از نظر **Data Provenance** پیشرفت مهمی نسبت به نسخه قبل است.

۴. Missing Data دیگر مخفی نمی شود

در نسخه Hourly تعداد:

۱۵

روز unresolved وجود دارد.

اما پروژه آن ها را:

- interpolation نمی کند

- forward-fill نمی کند

- bar مصنوعی نمی سازد

- حذف خاموش نمی کند

بلکه Coverage آن ها را نگه می دارد.

مثلاً:

downloaded downloaded unresolved downloaded ...

این رویکرد درست تری برای Financial Time Series است.

۵. مهم تر: Sequence دیگر از Gap عبور نمی کند

این یکی از بهترین اصلاحات نسخه جدید است.

فرض کن:

Day A Day B Day C ← missing Day D Day E

مدل نباید تصور کند:

Day B → Day D

یک توالی عادی بدون شکست است.

نسخه جدید داده را به **Segment** تقسیم می کند.

در خروجی فعلی:

8 Segments

ساخته شده.

Sequence های LSTM اجازه ندارند از یک Segment به Segment بعدی عبور کنند.

یعنی:

$Sequence_t \nrightarrow KnownMissingDate$

این اصلاح از نظر جلوگیری از ساخت الگوی زمانی جعلی بسیار مهم است.

۶. Indicator ها هم بعد از Gap Reset می شوند

نسخه قبل Rolling Indicator ها را روی سری روزانه محاسبه می کرد.

نسخه جدید برای Hourly Data بعد از روزهای unresolved دوباره Indicator ها را Warm-up می کند.

مثلاً اگر یک Gap وجود داشته باشد:

Segment 1 ————— SMA EMA RSI MACD [missing date] Segment 2
————— SMA warm-up again EMA warm-up again RSI warm-up again ...

در نتیجه اطلاعات دو طرف یک Gap نامعلوم با هم مخلوط نمی شوند.

۷. Target پروژه تغییر بنیادی کرده

نسخه قبلی مستقیم قیمت را Forecast می کرد:

$$P_{t+1}$$

این برای Financial Time Series همیشه ایده آل نیست، چون Price Level می تواند در طول سال ها بسیار تغییر کند.

نسخه جدید از:

"target_mode": "log_return"

استفاده می کند.

یعنی Target تبدیل شده به:

$$r_{t+1} = \ln\left(\frac{P_{t+1}}{P_t}\right)$$

مدل ابتدا:

$$\hat{r}_{t+1}$$

را پیش بینی می کند.

بعد قیمت بازسازی می شود:

$$P_{t+1} = P_t e^{\hat{r}_{t+1}}$$

این تغییر از نظر Time-Series Modeling قابل دفاع تر از یادگیری مستقیم Price Level است.

۸. ارتباط بسیار خوبی با Persistence ایجاد شده

یک ویژگی ظریف ولی مهم طراحی جدید این است که اگر مدل بگوید:

$$\hat{r}_{t+1} = 0$$

آنگاه:

$$P_{t+1} = P_t e^0 = P_t$$

پس دقیقاً به:

Persistence

می‌رسیم.

بنابراین LSTM عملاً یاد می‌گیرد:

«آیا دلیلی دارم از پیش‌بینی ساده‌ی قیمت فعلی منحرف شوم؟»

این formulation از نسخه قبل منطقی‌تر است.

۹. Feature Engineering از Absolute به

Relative تغییر کرده

نسخه قبلی Feature‌هایی مثل:

adj_open adj_high adj_low adj_official_close SMA EMA rolling_max ...

را تا حد زیادی در مقیاس قیمت وارد مدل می‌کرد.

نسخه جدید در حالت Hourly بسیاری از آن‌ها را نسبی می‌کند.

مثلاً:

$$OpenToLast = \frac{Open}{Last} - 1$$

$$HighToLast = \frac{High}{Last} - 1$$

$$LowToLast = \frac{Low}{Last} - 1$$

Moving Averageها هم نسبی شده‌اند

به جای اینکه:

$$SMA_{20} = 2500$$

مستقیماً به مدل داده شود، چیزی شبیه:

$$\frac{SMA_{20}}{Price_t} - 1$$

استفاده می‌شود.

این باعث می‌شود مدل کمتر به:

«فولاد در سال ۱۴۰۱ قیمتش ۱,۵۰۰ بوده ولی در سال ۱۴۰۵ مثلاً ۳,۰۰۰ شده»

وابسته شود.

مدل بیشتر ساختار نسبی بازار را می‌بیند.

۱۰. Volume هم بهتر Transform شده

در نسخه Hourly اضافه شده:

$$\text{LogVolume} = \ln(1 + \text{Volume})$$

یعنی:

log_volume

که معمولاً برای Distribution های شدیداً Skewed مثل حجم معاملات مناسب‌تر از Volume خام است.

۱۱. Feature های زمانی ساعتی اضافه شده‌اند

نسخه قبلی داشت:

weekday_sin weekday_cos jalali_month_sin jalali_month_cos

نسخه جدید علاوه بر آن‌ها:

hour_sin hour_cos elapsed_hours_feature

را اضافه کرده.

Hour نیز Cyclic Encode شده:

$$Hour_{\sin} = \sin\left(\frac{2\pi h}{24}\right)$$
$$Hour_{\cos} = \cos\left(\frac{2\pi h}{24}\right)$$

که برای Intraday patterns مفیدتر از یک عدد خام مثل:

۱۲ ۱۱ ۱۰ ۹

است.

۱۲. تعداد Feature ها

نسخه قبلی:

۴۸

Feature داشت.

نسخه Hourly جدید:

۴۹

Feature دارد.

اما تفاوت مهم‌تر کیفیت Feature Representation است، نه عدد ۴۸ در برابر ۴۹.

۱۳. Dataset مؤثر تقریباً چهار برابر شده

نسخه Daily بعد از Feature Engineering:

۱۰۰۴

Feature Row داشت.

نسخه Hourly:

Feature Bar دارد.

تقریباً:

$$\frac{4009}{1004} \approx 3.99$$

یعنی تقریباً ۴ برابر Observation قابل استفاده.

۱۴. Train / Validation / Test هم تقریباً چهار برابر

شده‌اند

نسخه قبلی

Samples	Split
۶۱۸	Train
۱۳۲	Validation
۱۳۴	Test

نسخه جدید

Samples	Split
۲,۴۹۰	Train
۵۳۳	Validation
۵۳۵	Test

تقریباً:

$$4 \times$$

داده بیشتر برای هر Split وجود دارد.

البته Windowهای Time Series هنوز overlap دارند؛ بنابراین نمی‌توان گفت ۲,۴۹۰ مشاهده کاملاً مستقل داریم.

۱۵. Sequence Length ها با داده Hourly سازگار

شده‌اند

قبلاً:

۶۰، ۳۰، ۱۰

جلسه معاملاتی.

الان:

۶۰، ۲۴، ۱۲

Observed Bars.

شش Candidate هنوز وجود دارد:

$3 \text{ sequence lengths} \times 2 \text{ unit sizes}$

یعنی:

12×32 12×64 24×32 24×64 60×32 60×64

۱۶. بهترین Architecture هم تغییر کرده

نسخه Daily:

$60 \text{ sessions} \times 64 \text{ units}$

انتخاب شده بود.

نسخه Hourly:

$60 \text{ bars} \times 32 \text{ units}$

انتخاب شده.

Validation RMSE:

۲۹٫۲۱۰

بوده است.

نکته جالب اینکه مدل ۳۲-unit از مدل پیچیده‌تر ۶۴-unit کمی بهتر شده.

یعنی باز هم:

Bigger model $\neq$ Better model

۱۷. تنظیم Training کمی تغییر کرده

جدید	قبلی	Parameter
۳۲ / ۶۴	۳۲ / ۶۴	Units

جدید	قبلی	Parameter
۱۲/۲۴/۶۰	۱۰/۳۰/۶۰	Sequence
۰/۲	۰/۲	Dropout
۰/۰۰۱	۰/۰۰۱	Learning Rate
۱۰۰	۱۰۰	Epoch max
۶۴	۳۲	Batch Size
۱۲	۱۰	Patience
۴۲	۴۲	Seed

Architecture هنوز ساده و کنترل شده باقی مانده:

Input ↓ LSTM ↓ Dropout ↓ Dense(1)

که برای مقایسه علمی بهتر از افزایش بی دلیل پیچیدگی است.

۱۸. GPU حالا به صورت واقعی enforce می شود

Config جدید دارد:

"required_gpu":"A100"

و Training قبل از شروع GPU را بررسی می کند.

اگر A100 در TensorFlow قابل مشاهده نباشد:

Training stops

نسخه Hourly نهایی روی:

NVIDIA A100-SXM4 40 GB

اجرا شده.

نسخه Daily قبلی روی A100 با ۸۰ GB اجرا شده بود.

بنابراین این مورد را نباید «GPU قوی تر» دانست؛ بهبود واقعی این است که محیط اجرای آزمایش **explicit** و **enforce** شده است.

۱۹. نتیجه مدل‌ها: تغییر بسیار مهم

نسخه قبلی Daily —

RMSE	Model
۶۰,۸۰۱	Persistence
۲۶۱,۷۴۶	Ridge
۳۹۰,۷۷۷	OHLCV LSTM
۴۶۷,۰۷۱	Full LSTM

Full LSTM نسبت به Persistence:

$7.68 \times$

بدتر بود.

یعنی:

668.2%

RMSE بیشتر.

۲۰. نسخه جدید Hourly —

MAPE	RMSE	MAE	Model
۰,۹۳۵%	۳۳,۰۴۹	۲۲,۶۴۶	Full-feature LSTM
۰,۸۳۲%	۳۲,۷۹۳	۲۰,۳۲۲	Persistence
۲,۱۴۹%	۹۹,۱۳۲	۵۲,۳۷۳	Ridge
۰,۹۲۳%	۳۲,۱۴۳	۲۲,۴۵۲	OHLCV-only LSTM

Full LSTM اکنون فقط:

0.78%

از Persistence در RMSE بدتر است.

نسبت:

$$\frac{33.049}{32.793} \approx 1.008$$

یعنی تقریباً برابر شده‌اند.

۲۱. این پیشرفت نسبت به Baseline بسیار چشمگیر است

قبلاً:

$$RMSE_{lstm} = 7.68 \times RMSE_{persistence}$$

الان:

$$RMSE_{lstm} = 1.008 \times RMSE_{persistence}$$

از نظر فاصله با Baseline همان آزمایش، این بهبود بسیار بزرگی است.

ولی باید یک هشدار جدی گذاشت:

نمی‌توان گفت RMSE از ۴۶۷ به ۳۳ کاهش یافته و بنابراین Accuracy مثلاً ۹۳٪ بهتر شده است.

چون Target ها متفاوت‌اند:

Daily

Next Session Official Close

Hourly

Next Observed Hourly Last Price

پس مقایسه raw RMSE بین این دو آزمایش سیب با سیب نیست.

۲۲. برای اولین بار یک LSTM از Persistence در RMSE جلو زده

این نتیجه جدید مهم است.

OHLCV-only LSTM:

$$RMSE = 32.143$$

در حالی که Persistence:

$$RMSE = 32.793$$

بنابراین:

$$1 - \frac{32.143}{32.793} \approx 1.98\%$$

یعنی OHLCV LSTM تقریباً:

$$1.98\%$$

RMSE کمتری از Persistence داشته است.

این اولین نشانه در پروژه است که یک Neural Model روی Test Set در یکی از معیارها Baseline ساده را شکست داده.

۲۳. اما این نتیجه نباید بیش از حد بزرگ شود

OHLCV-LSTM در RMSE بهتر است، ولی:

MAE

$$22.452 > 20.322$$

و MAPE:

$$0.923\% > 0.832\%$$

است.

یعنی Persistence هنوز در MAE و MAPE بهتر است.

پس نتیجه صحیح:

OHLCV LSTM در RMSE کمی بهتر است، ولی به طور کلی بر Persistence مسلط نشده است.

۲۴. Full Feature Engineering باز هم برنده نشده

Full-feature LSTM:

$$RMSE = 33.049$$

OHLCV-only:

$$RMSE = 32.143$$

یعنی Feature Engineering گسترده هنوز از OHLCV ساده بهتر نشده.

این الگوی نسخه قبلی هم حفظ شده است.

در واقع:

$$RMSE_{ohlc-lstm} < RMSE_{full-feature lstm}$$

در Test RMSE.

پس یک نتیجه علمی پروژه تقویت شده:

تعداد زیاد Technical Indicator الزاماً Predictive Signal ایجاد نمی‌کند.

۲۵. یک نکته مثبت مهم: بعد از دیدن Test انتخاب مدل

عوض نشده

Validation گفته:

$$60 \times 32$$

Full-feature LSTM بهترین Candidate است.

روی Test، OHLCV-LSTM کمی RMSE بهتری داشته.

اما پروژه نگفته:

پس OHLCV را مدل اصلی اعلام کنیم.

بلکه همان Validation-selected model را مدل اصلی نگه داشته.

این رفتار صحیح است، چون در غیر این صورت:

Test Set

عملاً تبدیل به Validation Set می‌شد.

۲۶. Reproducibility هم قوی‌تر شده

نسخه قبلی Model Reload داشت.

نسخه جدید علاوه بر آن:

- .keras reload
- .h5 reload
- Ridge reload
- OHLCV model reload
- scaler verification
- sequence reconstruction
- full metrics reproduction
- Colab verification
- independent local CPU verification
- source hashes
- bundle checksums
- raw trade checksums

دارد.

۲۷. Cross-environment verification اضافه شده

مدل روی:

TensorFlow 2.20 A100

آموزش دیده.

بعد مدل روی CPU و محیط دیگر دوباره تست شده.

برای OHLCV model حداکثر اختلاف:

0.009377 Rial

ثبت شده.

و tolerance رسمی:

0.01 Rial

است.

این یک ارتقای خوب برای reproducibility واقعی است.

۲۸. تعداد تست‌ها هم افزایش پیدا کرده

نسخه قبلی:

۲۷

Test پاس شده داشت.

نسخه جدید گزارش می‌کند:

۳۰

Test پاس شده‌اند، همراه با یک optional training integration test که skip شده.

همچنین فایل جدید:

tests/test_hourly.py

موارد مهمی را تست می‌کند، از جمله:

- Daily adjustment only once per session
- Gap handling
- Sequence gap prevention
- Training-only scaling
- Log-return reconstruction
- Persistence equivalence
- Feature causality
- Hourly/Daily config separation

۲۹. Causality test بهتر شده

تست جالبی اضافه شده که بخشی از داده‌های آینده را تغییر می‌دهد و بررسی می‌کند Feature های گذشته تغییر نکنند.

از نظر مفهومی:

FutureData → *PastFeature*

اگر داده آینده سه برابر شود، Feature مربوط به گذشته نباید تغییر کند.

این تست برای جلوگیری از Look-ahead Leakage بسیار ارزشمند است.

۳۰. Hourly و Daily حالا از هم جدا شده‌اند

Config جدید:

configs/hourly.json

اضافه شده.

import-hourly

وجود دارد.

همچنین کد اجازه نمی‌دهد Snapshot Hourly را اشتباهاً با Config روزانه پردازش کنی. این جداسازی Architecture پروژه را تمیزتر کرده است.

۳۱. Notebook مستقل Hourly اضافه شده

نسخه قبلی:

marketforecast_colab.ipynb

داشت.

الان:

marketforecast_hourly_colab.ipynb

نیز اضافه شده.

این Notebook:

verify bundle → run tests → train → verify models → package results

را انجام می‌دهد.

۳۲. Output artifact ها بسیار کامل‌تر شده‌اند

نسخه جدید نتیجه کامل Hourly را مستقیماً در Repo منتشر کرده:

results/ ├── foolad-hourly-a100/ |── data/ | |── snapshot/ |──
training-results/ | |── hourly-forecast/ |── provenance/

و یک archive قابل حمل نیز دارد:

artifacts/ ├── foolad-hourly-a100-results.zip

به همراه:

.sha256

۳۳. Provenance ساختاریافته‌تر شده

نسخه جدید حتی نسخه‌ی دقیق Source Code استفاده‌شده هنگام Training را نگه داشته:

provenance/ ├── training-source/

یعنی اگر در آینده کد main تغییر کند، هنوز می‌توان فهمید:

«مدلی که این metrics را تولید کرده دقیقاً با چه source code ای ساخته شده است؟»

این از لحاظ MLOps / Research Reproducibility ارتقای مهمی است.

۳۴. یک فایل آموزشی TSA هم اضافه شده

فایل جدید:

notes/Time_Series_Analysis_(TSA).md

حدود ۱,۵۰۰ خط محتوای آموزشی دارد.

این مستقیماً Performance مدل را بهتر نمی‌کند، ولی Repo را از صرفاً پروژه اجرایی به ترکیب:

implementation + experiment + documentation + learning notes

تبدیل کرده است.

۳۵. مقایسه نهایی

نسخه جدید	نسخه قبلی	جنبه
✓ حفظ شده	✓	Daily Forecasting
✓	✗	Hourly Forecasting
✓	✗	Raw trade retrieval
✓	✗	Raw trade verification
✓ explicit	محدود	Coverage log
✓	✗	Missing-date segmentation
✓	✗	Indicator reset after gap
Daily only	✓	Absolute-price target
✓ Hourly	✗	Log-return target
✓ گسترده‌تر	محدود	Relative features
✓	✗	Hour cyclic features
۴,۰۰۹	۱,۰۰۴	Usable observations
۲,۴۹۰	۶۱۸	Train samples
۵۳۵	۱۳۴	Test samples
✓ A100	✗	Training GPU enforcement
✓	✓	Model reload verification
✓	محدود	Local independent verification

نسخه جدید	نسخه قبلی	جنبه
گسترده‌تر		Raw/source checksums
30 passed	۲۷	Tests
کامل‌تر		Portable result bundle
تقریباً برابر	بسیار ضعیف	LSTM vs Persistence
OHLCV-LSTM +1.98%		Any NN beating Persistence RMSE

مهم‌ترین بهبود واقعی از نظر Data Science

اگر بخواهم تغییرات را از نظر اهمیت رتبه‌بندی کنم:

- ۱ تغییر Target از Price Level به Log Return
- ۲ استفاده از Feature های Relative به جای Price Scale خام
- ۳ افزایش حدود چهاربرابری تعداد Sample ها با Hourly Data
- ۴ عدم عبور Sequence ها و Indicators از Missing Dates
- ۵ بازسازی و Verify هر Hourly Bar از Raw Trades
- ۶ حفظ Test Set به عنوان Test واقعی و عدم انتخاب مدل بر اساس Test
- ۷ Cross-environment reproducibility
- ۸ بهبود شدید فاصله LSTM با Persistence

اما هنوز سه محدودیت جدی وجود دارد

اول اینکه Full-feature LSTM هنوز Persistence را شکست نداده:

$$33.049 > 32.793$$

بنابراین هنوز نمی‌توان گفت Feature-rich LSTM predictive advantage اثبات کرده است.

دوم، OHLCV-LSTM فقط در RMSE حدود ۱/۹۸٪ بهتر است؛ در MAE و MAPE همچنان Persistence بهتر است. این evidence مثبت است، ولی ضعیف و نیازمند تکرار روی بازه‌ها و نمادهای دیگر.

سوم، در داده Hourly هنوز bar ۲۳۶ در ساعت ۱۳:۰۰ یا بعد از آن وجود دارد که classification دقیق session آن‌ها مستقلاً تأیید نشده. پروژه درست عمل کرده و آن‌ها را مخفیانه حذف نکرده، اما برای یک نسخه Research-grade بعدی بهتر است این موضوع بررسی شود. همچنین ۱۵ روز unresolved هنوز باقی مانده‌اند.

یک نکته مستندی هم وجود دارد: docs/implementation_status.md در diff اصلی Hourly به‌روزرسانی نشده و همچنان بیشتر وضعیت آزمایش Daily را منعکس می‌کند؛ در حالی که

docs/hourly_experiment.md وضعیت جدید را پوشش می‌دهد. یکپارچه کردن این دو، README و لینک‌های Colab می‌تواند ساختار مستندات را تمیزتر کند.

ارزیابی کلی

نسخه قبلی را می‌شد یک پروژه خوب **Forecasting** با تأکید بر **reproducibility** دانست.

نسخه فعلی بیشتر شبیه یک **Research-grade time-series experimentation pipeline** شده است:

Hourly Data → Log Return Forecasting → Baseline Comparison → Independent Verification

و مهم‌ترین پیشرفت عددی هم این نیست که «RMSE از ۴۶۷ به ۳۳ رسیده»؛ آن مقایسه معتبر نیست. پیشرفت معتبرتر این است که **Full LSTM** از ۶۶۸٪ بدتر از **Persistence** در آزمایش قبلی، به تنها ۰٫۷۸٪ بدتر در آزمایش **Hourly** رسیده و **OHLCV-LSTM** حتی در RMSE حدود ۱٫۹۸٪ از **Persistence** جلو زده است. این هنوز اثبات برتری **LSTM** نیست، ولی نسبت به نسخه قبلی نتیجه بسیار امیدوارکننده‌تر و طراحی آزمایش به‌مراتب قوی‌تر شده است.