

راهنمای مفاهیم و الگوریتم‌های پیش‌بینی بازار با

LSTM

مبانی مالی و ریاضی آزمایش‌های روزانه و ساعتی سهم فولاد

راهنمای آموزشی پروژه | ۱۵ مهر ۱۴۰۵

این پروژه پیش‌بینی قیمت سهم فولاد مبارکه را در دو مقیاس روزانه و ساعتی بررسی می‌کند. برای فهم نتیجه، باید مسیر داده را از معامله خام تا خطای پیش‌بینی دنبال کنیم. نام LSTM به‌تنهایی چیزی درباره کیفیت پیش‌بینی نمی‌گوید؛ کیفیت داده، تعریف هدف و روش ارزیابی تعیین می‌کنند که نتیجه چه معنایی دارد.

در آزمایش روزانه، مدل قیمت پایانی رسمیِ تعدیل‌شده جلسه معاملاتی بعد را پیش‌بینی می‌کند. در آزمایش ساعتی، مدل بازده لگاریتمی کندل مشاهده‌شده بعد را می‌آموزد و از آن آخرین قیمت تعدیل‌شده را بازسازی می‌کند. این دو هدف از نظر قیمت مبنا و افق زمانی متفاوت‌اند. در هر دو آزمایش، مدل کامل LSTM در آزمون نهایی از مبنا تداوم قیمت بهتر نشده است.

این راهنما برای مطالعه آموزشی و توضیح روش پروژه نوشته شده است. هر مفهوم ابتدا با زبان ساده معرفی می‌شود، سپس رابطه ریاضی و جای آن در پیاده‌سازی توضیح داده می‌شود. مثال‌های عددی آموزشی از نتایج واقعی آزمایش جدا هستند. فصل مربوط به ARIMA و هموارسازی نمایی، مفاهیم یادداشت آموزشی پروژه را پوشش می‌دهد؛ این مدل‌ها در مسیر آموزش نهایی اجرا نشده‌اند.

فهرست مطالب

عنوان هر فصل به متن آن پیوند دارد. زیرعنوان‌ها در پنل ناوبری Word دیده می‌شوند.

صفحه	فصل
۳	۱ صورت مسئله و نقشه پروژه
۴	۲ مفاهیم مالی و ساختار قیمت
۷	۳ مبانی سری زمانی
۸	۴ دریافت پاک‌سازی و کنترل داده
۱۰	۵ تعدیل گذشته‌نگر قیمت
۱۱	۶ مهندسی ویژگی‌های قیمت و حجم
۱۴	۷ اندیکاتورهای فنی و قراردادهای دقیق آن‌ها
۱۶	۸ ویژگی‌های تقویمی و نمایش نسبی ساعتی
۱۷	۹ تبدیل سری زمانی به نمونه یادگیری
۱۸	۱۰ استانداردسازی و جلوگیری از نشت اطلاعات
۱۹	۱۱ شبکه عصبی بازگشتی و LSTM
۲۲	۱۲ آموزش تابع زیان و بهینه‌سازی
۲۴	۱۳ مدل‌های مبنا و حذف گروه ویژگی
۲۵	۱۴ ارزیابی خطا و نمودارها
۲۷	۱۵ آزمایش روزانه و نتایج واقعی
۲۸	۱۶ آزمایش ساعتی و نتایج واقعی
۳۰	۱۷ ذخیره‌سازی بازتولید و آزمون‌های نرم‌افزار
۳۲	۱۸ مدل‌های آموزشی مکمل در یادداشت TSA
۳۴	۱۹ واژه‌نامه کاربردی و دام‌های تفسیر
۳۶	۲۰ پیوست فهرست دقیق ویژگی‌ها
۴۲	۲۱ پیوست نمادها و منابع

۱ صورت مسئله و نقشه پروژه

۱.۱ تعریف پیش‌بینی و اطلاعات در دسترس

فرض کنیم مشاهده جاری تمام شده است. در این لحظه، قیمت‌های همین مشاهده و همه مشاهدات قبل از آن معلوم‌اند. مدل یک عدد برای مشاهده بعد تولید می‌کند. این مسئله «رگرسیون نظارت‌شده تک‌گامی» است؛ هدف یک مقدار عددی است و برچسب هر نمونه از مشاهده بعد می‌آید.

برای جلوگیری از ابهام، در این سند t شماره هدف است. آخرین ورودی شماره $t - 1$ دارد. اگر طول پنجره L و تعداد ویژگی‌ها d باشد، ورودی یک ماتریس با L ردیف زمانی و d ستون ویژگی است.

$$X_t = [x_{t-L}, \dots, x_{t-1}], \quad X_t \in \mathbb{R}^{L \times d} \quad (۱)$$

هدف روزانه $y_t = P_t$ است؛ P_t قیمت پایانی رسمی تعدیل‌شده است. در حالت ساعتی، P_t آخرین قیمت تعدیل‌شده کندل است و هدف آموزشی، لگاریتم نسبت آن به قیمت کندل قبل خواهد بود. بردار x_s فقط از اطلاعاتی ساخته می‌شود که تا پایان مشاهده s قابل محاسبه‌اند.

در کد `sequences.py` برش `t-length:t` همین قرارداد را اجرا می‌کند. در مستندات پروژه گاهی زمان جاری با t نام‌گذاری می‌شود و هدف $t + 1$ است؛ دو قرارداد یک پیش‌بینی واحد را توصیف می‌کنند. جابه‌جایی اندیس‌ها نباید به استفاده از قیمت هدف در ورودی منجر شود.

۱.۲ تفاوت آزمایش‌های روزانه و ساعتی

ویژگی	روزانه	ساعتی
قیمت هدف	قیمت پایانی رسمی تعدیل‌شده	آخرین قیمت تعدیل‌شده کندل
هدف آموزش	سطح قیمت	بازده لگاریتمی
افق	جلسه معاملاتی مشاهده‌شده بعد	کندل معامله‌دار مشاهده‌شده بعد
طول پنجره‌های نامزد	۱۰، ۳۰، ۶۰ جلسه	۱۲، ۲۴، ۶۰ کندل
تعداد ویژگی	۴۸	۴۹
ورودی منتخب	پنجره ۶۰ جلسه‌ای	پنجره ۶۰ کندلی
واحد خطای قیمت	ریال تعدیل‌شده	ریال تعدیل‌شده

«مشاهده بعد» لزوماً فردای تقویمی یا دقیقاً یک ساعت بعد نیست. تعطیلی، توقف نماد و پایان جلسه می‌توانند فاصله زمانی را زیاد کنند. بنابراین مدل افق ثابتی در شمار مشاهدات دارد، اما فاصله ساعت و روز بین دو مشاهده ممکن است تغییر کند.

۱.۳ مسیر پردازش

داده ابتدا دریافت یا از خروجی کاربر وارد می‌شود، سپس در یک مجموعه ثابت ذخیره و با اثرانگشت فایل‌ها کنترل می‌شود. پاک‌سازی و تعدیل قیمت پیش از مهندسی ویژگی انجام می‌شوند. پس از ساخت پنجره‌ها، داده به آموزش، اعتبارسنجی و آزمون تقسیم می‌شود. مقیاس‌سازها فقط با آموزش برازش می‌شوند؛ انتخاب مدل روی اعتبارسنجی انجام می‌شود؛ آزمون برای گزارش نهایی باقی می‌ماند.

وظیفه اصلی	ماژول
دریافت روزانه، تطبیق نماد، پاک‌سازی و تعدیل	data.py
ورود خروجی‌های روزانه و کنترل مبنای تعدیل	import_export.py
ورود کندل ساعتی، کنترل پوشش و شکاف‌ها	hourly.py
ویژگی‌های قیمت، حجم، اندیکاتور و تقویم	features.py
اهداف مشترک، تقسیم زمانی و استانداردسازی	sequences.py
آموزش LSTM، انتخاب مدل و مدل‌های مقایسه‌ای	training.py
معیارهای خطا و نمودارهای خروجی	evaluation.py
هماهنگی اجرا، ذخیره‌سازی و بازتولید	io.py و workflow.py

۲ مفاهیم مالی و ساختار قیمت

۲.۱ سهم نماد و شناسه ابزار

سهم، واحد مالکیت در شرکت است. نماد «فولاد» نام معاملاتی سهم فولاد مبارکه اصفهان است. شناسه ابزار، نام نماد و نام شرکت یکسان نیستند. کد دریافت زنده، نماد نرمال‌شده و نام شرکت را هم‌زمان بررسی می‌کند تا ابزار دیگری با نام شبیه وارد داده نشود. شناسه ذخیره‌شده برای این آزمایش 46348559193224090 و شناسه بین‌المللی ثبت‌شده در ورود روزانه IRO1FOLD0001 است.

نرمال سازی نام، «ی» و «ك» عربی را به «ی» و «ك» فارسی تبدیل می کند و فاصله های نام را برای مقایسه کنار می گذارد. این کار فقط برای شناسایی ابزار است؛ متن آموزشی باید نیم فاصله و نگارش فارسی را حفظ کند.

۲.۲ قیمت بازشدن بیشینه کمینه و آخرین معامله

قیمت بازشدن، قیمت اولین معامله بازه است. بیشینه و کمینه، بزرگ ترین و کوچک ترین قیمت معاملات همان بازه اند. آخرین قیمت، قیمت آخرین معامله بازه است. این چهار مقدار شکل کندل را می سازند. در داده ساعتی، ستون `hourly_last_price` آخرین معامله ساعت را نگه می دارد؛ این ستون قیمت پایانی رسمی روز نیست.

اگر قیمت بازشدن یا آخرین معامله بیرون از فاصله کمینه تا بیشینه باشد، کندل ناسازگار است. این کنترل برای قیمت پایانی رسمی روز اعمال نمی شود، چون این قیمت از سازوکار رسمی تعیین قیمت پایانی می آید و لازم نیست دقیقاً یک معامله همان روز باشد.

$$L_t \leq O_t \leq H_t, \quad L_t \leq P_t^{last} \leq H_t \quad (۲)$$

در این رابطه، O_t قیمت بازشدن، H_t بیشینه و L_t کمینه اند. نماد L_t برای کمینه قیمت با L برای طول پنجره تفاوت دارد؛ زیرنویس زمانی این دو را از هم جدا می کند.

۲.۳ قیمت پایانی رسمی و حجم مبنا

قیمت پایانی رسمی، مرجع پایان روز معاملاتی است. مفهوم آن را می توان با میانگین موزون معاملات و قواعد بازار فهمید. میانگین موزون قیمت معامله، مجموع ارزش معاملات تقسیم بر مجموع حجم است. سازوکار رسمی می تواند اثر قواعدی مانند حجم مبنا را هم داشته باشد؛ پروژه این سازوکار را بازسازی نمی کند و مقدار منتشرشده را مستقیم می خواند.

$$VWAP = \frac{\sum_{j=1}^n p_j q_j}{\sum_{j=1}^n q_j} \quad (۳)$$

p_j و q_j قیمت و تعداد سهم در معامله j هستند. این رابطه تعریف میانگین موزون است و نباید با فرمول محاسبه قیمت پایانی رسمی این پروژه اشتباه شود. قواعد روز بازار و جزئیات حقوقی حجم مبنا برای محاسبات این پژوهش لازم نیستند، زیرا ستون رسمی آماده مصرف می شود.

در نگاشت `TSETMC`، ستون `pClosing` قیمت پایانی رسمی و `pDrCotVal` آخرین معامله است. در نگاشت خروجی `pytse-client`، نام `adjClose` به `official_close` و نام `close` به `last_trade` تبدیل می شود. نام `adjClose` در یک فایل خام به تنهایی اثبات نمی کند که عدد قبلاً تعدیل شده است؛ حالت دریافت و کنترل فایل مرجع تعیین کننده اند.

۲.۴ حجم ارزش و تعداد معاملات

حجم، تعداد سهم مبادله شده است؛ ارزش، مجموع مبلغ معاملات است؛ تعداد معاملات، شمار ثبت های معامله است. این سه متغیر واحد یکسان ندارند. تقسیم ارزش بر حجم می تواند میانگین موزون قیمت را بدهد، ولی تقسیم ارزش بر تعداد معاملات، مبلغ متوسط هر معامله را می دهد.

$$V_t = \sum_{j=1}^{n_t} q_j, \quad A_t = \sum_{j=1}^{n_t} p_j q_j \quad (۴)$$

در این سند V_t حجم بر حسب سهم و A_t ارزش بر حسب ریال است. قیمت های پروژه ریالی اند؛ تبدیل آن ها به تومان بدون تبدیل معیارهای خطا، جدول نتایج را غلط می کند. حجم را هم نباید با ارزش یا نقدشوندگی کامل معادل دانست. صف خرید و فروش، فاصله قیمت سفارش ها و امکان اجرای سفارش در این داده های ورودی مدل اندازه گیری نشده اند.

۲.۵ سود نقدی افزایش سرمایه و تعدیل

رویداد شرکتی می تواند قیمت مبنا را تغییر دهد، بدون آنکه افت خام قیمت همان معنای زیان معمول بازار را داشته باشد. سود نقدی و افزایش سرمایه از نمونه های این رویدادها هستند. برای مقایسه قیمت های دوره های مختلف، تاریخچه به یک مبنا تعدیل مشترک برده می شود.

پروژه علت حقوقی هر تغییر را از صورت های مالی استخراج نمی کند. به جای آن، نسبت «قیمت پایانی دیروز گزارش شده برای جلسه بعد» به «قیمت پایانی جلسه جاری» را به کار می گیرد. اگر این نسبت با یک تفاوت داشته باشد، نشانه تغییر مرجع است. یک تغییر بزرگ خام هم صرفاً علامت گذاری می شود؛ خودکار حذف نمی شود.

۲.۶ بازده ریسک و سود معامله

بازده ساده نسبت تغییر قیمت به قیمت مبناست. نوسان بازده در این پروژه یک توصیف آماری از پراکندگی تغییرات گذشته است. نوسان، همه ریسک های سرمایه گذاری را پوشش نمی دهد. ریسک نقدشوندگی، توقف معاملات و عدم امکان اجرا در صف، به داده و مدل دیگری نیاز دارند.

پیش بینی قیمت با سودآوری معامله برابر نیست. برای سودآوری باید زمان تصمیم، قیمت واقعی اجرا، هزینه ها، محدودیت معامله و قواعد نگهداری موقعیت تعریف شوند. چنین راهبردی در پروژه ساخته نشده است. بنابراین خطای کمتر را می توان مزیت پیش بینی دانست، اما نمی توان آن را به درصد سود قابل تحقق تبدیل کرد.

۳ مبانی سری زمانی

۳.۱ ترتیب زمان و وابستگی مشاهدات

سری زمانی مجموعه‌ای از مشاهدات مرتب‌شده بر اساس زمان است. در اینجا قیمت و حجم به شماره جلسه یا کندل وابسته‌اند. مرتب‌سازی فقط ظاهر جدول را عوض نمی‌کند؛ ترتیب ورودی تعیین می‌کند مدل کدام گذشته را دیده است. به همین دلیل تقسیم تصادفی معمول داده‌های جدولی برای این آزمایش مناسب نیست. دو کندل مجاور می‌توانند اطلاعات مشابه داشته باشند. پنجره‌های متوالی نیز بیشتر ردیف‌هایشان مشترک است. در نتیجه ۱۰۰۰ پنجره الزاماً به معنای ۱۰۰۰ شاهد مستقل نیست. این وابستگی در تفسیر حجم داده، مقایسه مدل و طراحی آزمون آماری اثر دارد.

۳.۲ روند فصل چرخه و نویز

روند، تغییر جهت‌دار بلندمدت سطح سری است. فصل‌مندی، الگوی تکرارشونده با دوره تقویمی نسبتاً مشخص است؛ مانند تغییر رفتار در ساعت‌های مختلف جلسه. چرخه به نوسان‌های بلندتر و معمولاً نامنظم اقتصادی اشاره دارد. نویز بخشی باقی‌مانده‌ای است که با ساختار انتخاب‌شده توضیح داده نشده است.

$$Y_t = T_t + S_t + C_t + \varepsilon_t \quad (5)$$

این مدل جمعی، چارچوب آموزشی برای تفکیک اجزاست. در مدل ضربی، اجزا ضرب می‌شوند و دامنه نوسان می‌تواند همراه سطح سری رشد کند. اگر همه اجزا مثبت باشند، لگاریتم، ضرب را به جمع تبدیل می‌کند.

$$Y_t = T_t S_t C_t E_t, \quad \ln Y_t = \ln T_t + \ln S_t + \ln C_t + \ln E_t \quad (6)$$

پروژه تجزیه رسمی روند و فصل‌مندی انجام نمی‌دهد. میانگین‌های متحرک، ویژگی‌های تقویمی و بازده‌ها راه‌های وارد کردن بخشی از این اطلاعات به مدل‌اند. وجود ویژگی ماه یا ساعت هم اثبات نمی‌کند که فصل‌مندی آماری در داده تأیید شده است.

۳.۳ وقفه و خودهمبستگی

وقفه یک یعنی مقدار مشاهده قبل، نه لزوماً روز تقویمی قبل. وقفه پنج در داده ساعتی پنج کندل مشاهده‌شده عقب می‌رود. برای مثال، اگر پایان جلسه و آغاز جلسه بعد کنار هم باشند، وقفه یک از شکاف شبانه عبور می‌کند. خودهمبستگی رابطه خطی سری با نسخه عقب‌افتاده خودش را اندازه می‌گیرد. با فرض ایستایی، تعریف نظری آن چنین است.

$$\rho(k) = \frac{Cov(Y_t, Y_{t-k})}{Var(Y_t)} \quad (7)$$

نمودار ACF یا آزمون ایستایی در مسیر نهایی کد اجرا نشده است؛ این مفهوم برای فهم وابستگی زمانی و یادداشت TSA پروژه آمده است. یک خودهمبستگی بالای قیمت می‌تواند صرفاً از ماندگاری سطح و روند بیاید و به معنی پیش‌بینی‌پذیری بازده نیست.

۳.۴ ایستایی و تغییر رژیم

در ایستایی ضعیف، میانگین و واریانس با زمان تغییر نمی‌کنند و کوواریانس تنها به فاصله زمانی وابسته است. قیمت سهم معمولاً می‌تواند روند، تغییر سطح و تغییر نوسان داشته باشد. بازده یا نسبت‌های نسبی گاهی از سطح قیمت پایدارترند، اما این ویژگی باید بررسی شود؛ تبدیل داده به بازده به‌تنهایی ایستایی را تضمین نمی‌کند. تغییر رژیم یعنی رابطه گذشته و آینده در بخشی از تاریخ عوض شود. سیاست اقتصادی، شرایط شرکت یا رفتار بازار می‌تواند چنین تغییری بسازد. مدل برازش‌شده با دوره گذشته ممکن است در رژیم جدید خطای جهت‌دار بدهد. کم‌برآوردی قیمت‌های انتهای آزمون روزانه با این مسئله سازگار است، ولی به‌تنهایی علت آن را اثبات نمی‌کند.

۳.۵ زمان رویداد و زمان تقویمی

اندیکاتور ۲۰ دوره‌ای در این پروژه روی ۲۰ مشاهده محاسبه می‌شود. در روزانه، ۲۰ جلسه و در ساعتی، ۲۰ کندل معامله‌دار است. این طول در داده ساعتی لزوماً ۲۰ ساعت پیوسته نیست. تعطیلی معمول بازار نگه داشته می‌شود و با ویژگی فاصله زمانی قابل مشاهده است. روز حل‌نشده در دریافت داده با تعطیلی عادی فرق دارد. برای شکاف حل‌نشده، قطعه جدید شروع می‌شود و پنجره‌ای از آن عبور نمی‌کند. برای تعطیلی معلوم، پیوستگی در شمار مشاهدات حفظ می‌شود. این تفاوت اجازه می‌دهد افق تعریف‌شده پژوهش حفظ شود، بدون ساختن کندل مصنوعی.

۴ دریافت پاک‌سازی و کنترل داده

۴.۱ منابع داده و نگاشت ستون‌ها

پروژه هم مسیر دریافت روزانه از API مبتنی بر HTTPS دارد و هم مسیر ورود فایل‌های pytse-client. آزمایش‌های ذخیره‌شده از خروجی‌های واردشده استفاده کرده‌اند. پاسخ خام، نسخه بسته و زمان دریافت اولیه در بعضی خروجی‌های کاربر ثبت نشده است؛ زمان ورود فایل جای زمان واقعی دریافت از بازار را نمی‌گیرد.

مفهوم	نام TSETMC	نام نرمال‌شده
تاریخ	dEven	date

مفهوم	نام TSETMC	نام نرمال شده
قیمت نخست	priceFirst	open
بیشینه	priceMax	high
کمینه	priceMin	low
پایانی رسمی	pClosing	official_close
آخرین معامله	pDrCotVal	last_trade
مرجع روز قبل	priceYesterday	previous_official_close
حجم	qTotTran5J	volume
ارزش	qTotCap	value
تعداد معامله	zTotTran	trade_count

۴.۲ تاریخ کامل و خطاهای دریافت

در دریافت روزانه، جلسه جاری تهران کنار گذاشته می شود تا کندل کامل نشده وارد مطالعه نشود. درخواست ها مهلت ۱۵ ثانیه و حداکثر ۳ تلاش دارند؛ بین تلاش ها مکث محدود اعمال می شود. اعتبار گواهی HTTPS غیرفعال نشده است. نبود ستون لازم یا ساختار ناسازگار پاسخ، خطاست و با داده ساختگی جبران نمی شود.

تاریخ شمسی برای ویژگی های تقویمی و خواندن گزارش نگه داشته می شود؛ مرتب سازی و ذخیره زمانی بر پایه تاریخ قابل پردازش انجام می گیرد. در ساعتی، برچسب ها زمان محلی بدون منطقه زمانی صریح هستند و پروژه تبدیل منطقه زمانی انجام نداده است. این قرارداد باید هنگام اتصال خروجی به سامانه ای دیگر حفظ شود.

۴.۳ قواعد پاک سازی

قیمت ها باید مثبت و اعداد فعالیت نامنفی باشند. حجم و تعداد معامله باید عدد صحیح باشند. تاریخ نامعتبر، مقدار نامتناهی، معامله بدون حجم و کندل ناسازگار در ممیزی ثبت می شوند. رکوردهای یکسان تکراری ادغام می شوند، اما رکوردهای متفاوت برای یک تاریخ قرنطینه می شوند؛ انتخاب دلخواه یکی از آن ها مجاز نیست.

در روزانه، یک ردیف می تواند چند علت رد شدن داشته باشد. پس مجموع شمار علت ها می تواند از تعداد ردیف های قرنطینه بیشتر باشد. در آزمایش ذخیره شده، یک ردیف هم «قیمت نامثبت» و هم «کندل ناسازگار» دارد؛ این دو علت، دو ردیف مستقل نیستند.

اگر حذف یک روز معامله دار زنجیره تعدیل را ناقص کند، آماده سازی متوقف می شود. یک استثنای بررسی شده برای روز دارای قیمت باز شدن صفر وجود دارد: خود کندل از مدل حذف می شود، ولی مرجع پایانی معتبر آن در زنجیره کامل تعدیل باقی می ماند. این کار با مبنای تعدیل تأیید شده انجام می شود و مجوز حذف عمومی روزهای مشکل دار نیست.

۴.۴ داده مفقود و پرش خام

پروژه برای تعطیلی، توقف یا شکست دریافت، قیمت میان یابی شده تولید نمی کند. پرش خام بیش از ۱۵ درصد با raw_jump_flag مشخص می شود. این آستانه یک قاعده ممیزی کد است؛ قانون دامنه نوسان بازار نیست و علت پرش را مشخص نمی کند.

جایگزینی شکاف با آخرین قیمت می تواند حجم نمونه را ظاهراً زیاد کند و بازده های صفر ساختگی بسازد. چنین کاری توزیع اندیکاتورها و افق هدف را عوض می کند. در این پروژه، ردیف های نامعتبر و پنجره های عبوری از شکاف حذف یا مسدود می شوند و شمار آن ها ثبت می شود.

۵ تعدیل گذشته نگر قیمت

۵.۱ ضریب تک مرحله و ضریب تجمعی

قیمت پایانی خام جلسه s را C_s و مرجع قیمت پایانی قبلی در رکورد جلسه $s + 1$ را Y_{s+1} بنامیم. ضریب تک مرحله نسبت این دو است. ضریب آخرین جلسه برابر یک قرار می گیرد؛ بنابراین همه قیمت ها به مبنای انتهای تاریخچه منتقل می شوند.

$$a_s = \frac{Y_{s+1}}{C_s}, \quad a_T = 1 \quad (۸)$$

$$F_s = \prod_{u=s}^T a_u, \quad P_s^{adj} = F_s P_s^{raw} \quad (۹)$$

F_s ضریب تجمعی و T آخرین جلسه مبناست. همین ضریب برای همه فیلدهای قیمتی یک روز استفاده می شود. محاسبه با حاصل ضرب تجمعی در جهت معکوس انجام می شود و دقت اعشاری قیمت ها حفظ می شود. حجم سهم در این پیاده سازی با ضریب قیمت ضرب نمی شود.

۵.۲ مثال عددی تعدیل

فرض آموزشی: قیمت پایانی جلسه اول ۱۰۰۰ ریال است و در رکورد جلسه بعد، مرجع قبلی ۸۰۰ ریال آمده است. ضریب تک مرحله $۰/۸$ می شود. اگر رویداد دیگری بعد از آن نباشد، قیمت خام ۹۵۰ ریال در جلسه اول به ۷۶۰ ریال تبدیل می شود. حجم ۲۰۰۰ سهم، همان ۲۰۰۰ سهم می ماند.

$$a_1 = \frac{800}{1000} = 0.8, \quad P_1^{adj} = 950 \times 0.8 = 760 \quad (10)$$

این مثال درباره مکانیک محاسبه است؛ نوع رویداد شرکتی یا بازده سرمایه‌گذار را از این اعداد استنتاج نمی‌کنیم. برای بازده کل سرمایه‌گذاری باید جریان‌های نقدی و تغییر تعداد سهم جدا بررسی شوند.

۵.۳ مبنای تعدیل ساعتی

ضریب تعدیل ساعتی از قیمت‌های پایانی رسمی روزانه ساخته می‌شود، سپس به تمام کندل‌های همان روز پیوند می‌خورد. اگر یک روز چهار کندل داشته باشد، هر چهار کندل یک ضریب می‌گیرند. ضریب یک رویداد نباید به تعداد کندل‌ها تکرار و چند بار ضرب شود.

$$P_{d,h}^{adj} = F_d P_{d,h}^{raw} \quad (11)$$

در اینجا d روز و h ساعت کندل است. آخرین قیمت ساعتی مبنای تشخیص رویداد تعدیل نیست؛ استفاده از آن می‌تواند تغییر معمول معامله را با رویداد شرکتی اشتباه بگیرد.

۵.۴ تفاوت علیت ویژگی و علیت مبنای تعدیل

میانگین متحرک هر زمان، فقط از مقادیر همان زمان و قبل از آن ساخته می‌شود. این ویژگی روی سری تعدیل‌شده ثابت علی است. اما خود تعدیل رو به عقب از رویدادهای بعدی استفاده کرده است. پس کل پژوهش یک مطالعه گذشته‌نگر روی مبنای ثابت است.

آزمون علیت ویژگی‌ها، قیمت‌های آینده را با ثابت نگه داشتن مبنای تعدیل تغییر می‌دهد و بررسی می‌کند که ویژگی‌های گذشته تغییر نکنند. این آزمون نمی‌گوید که قیمت تعدیل‌شده امروز در همان روز تاریخی در دسترس بوده است. برای ارزیابی در زمان واقعی، داده رویدادهای شرکتی با تاریخ اطلاع و طرح ارزیابی متناسب لازم است.

۶ مهندسی ویژگی‌های قیمت و حجم

۶.۱ بازده ساده و بازده لگاریتمی

بازده ساده یک دوره‌ای در return_1 از قیمت مرجع تعدیل‌شده محاسبه می‌شود. در روزانه مرجع، پایانی رسمی و در ساعتی مرجع، آخرین قیمت کندل است.

$$r_t = \frac{P_t}{P_{t-1}} - 1 \quad (12)$$

بازده لگاریتمی هدف ساعتی است. جمع بازده‌های لگاریتمی برابر لگاریتم نسبت قیمت ابتدا و انتهای چند دوره می‌شود، مشروط به مثبت بودن قیمت‌ها.

$$\ell_t = \ln \frac{P_t}{P_{t-1}}, \quad \sum_{s=1}^m \ell_s = \ln \frac{P_m}{P_0} \quad (۱۳)$$

برای تغییرهای کوچک، بازده ساده و لگاریتمی نزدیک‌اند، ولی یکسان نیستند. مثال آموزشی: افزایش از ۱۰۰ به ۱۰۲، بازده ساده ۰٫۰۲ و بازده لگاریتمی حدود ۰٫۰۱۹۸ می‌دهد. به صورت درصدی، اولی ۲ درصد و دومی حدود ۱٫۹۸ درصد است. در کد، مقدار اعشاری بازده مصرف می‌شود، نه عدد درصدی.

۶.۲ وقفه‌های قیمت و بازده

وقفه‌ها برای فاصله‌های ۱، ۲ و ۵ ساخته می‌شوند. `return_lag_2` بازده محاسبه‌شده در دو مشاهده قبل است؛ بازده تجمیعی دو مشاهده نیست. این تفاوت کوچک، معنای ویژگی را عوض می‌کند.

$$\text{priceLag}_k(t) = P_{t-k}, \quad \text{returnLag}_k(t) = r_{t-k} \quad (۱۴)$$

در داده روزانه، وقفه قیمت سطح مطلق گذشته است. در داده ساعتی، همان ستون به نسبت قیمت گذشته به قیمت جاری منهای یک تبدیل می‌شود. نام ستون ثابت است، اما معنای عددی بین دو آزمایش فرق دارد.

$$\text{relativeLag}_k(t) = \frac{P_{t-k}}{P_t} - 1 \quad (۱۵)$$

۶.۳ میانگین متحرک ساده

میانگین متحرک ساده یا **SMA** میانگین w مشاهده اخیر است و خود مشاهده جاری را هم شامل می‌شود. پنجره‌های ۵، ۱۰ و ۲۰ به کار می‌روند. این ویژگی نوسان کوتاه‌مدت را نرم‌تر می‌کند، ولی تغییر ناگهانی قیمت را با تأخیر منعکس می‌کند.

$$\text{SMA}_w(t) = \frac{1}{w} \sum_{j=0}^{w-1} P_{t-j} \quad (۱۶)$$

اگر سه قیمت آموزشی ۱۰۰، ۱۰۲ و ۱۰۴ باشند، میانگین ساده سه دوره‌ای ۱۰۲ است. در پنجره ۲۰، هر مشاهده وزن یک‌بیستم دارد. در آغاز سری تا کامل شدن پنجره، مقدار ویژگی موجود نیست و ردیف در مرحله گرم‌شدن حذف می‌شود.

۶.۴ میانگین متحرک نمایی

EMA به داده جدید وزن بیشتری می‌دهد. در کد `ewm` با `adjust=False` و حداقل تعداد مشاهده برابر پنجره استفاده شده است. رابطه بازگشتی و وزن متناظر با پارامتر `span` چنین‌اند.

$$\alpha_w = \frac{2}{w+1}, \quad \text{EMA}_w(t) = \alpha_w P_t + (1 - \alpha_w) \text{EMA}_w(t-1) \quad (۱۷)$$

بازگشت از اولین مقدار سری شروع می‌شود، ولی انتشار ویژگی تا رسیدن به حداقل مشاهده عقب می‌افتد. این مقداردهی اولیه با بذر میانگین ساده روش وایلدِر یکسان نیست. **EMA** پنج دوره‌ای نسبت به **EMA** بیست دوره‌ای به تغییر تازه حساس‌تر است.

۶.۵ فاصله از میانگین و نقاط حدی

نسبت قیمت به SMA، فاصله نسبی قیمت جاری از میانگین را نشان می‌دهد. مقدار ۰/۰۵ یعنی قیمت ۵ درصد بالاتر از میانگین است. این ویژگی سیگنال قطعی خرید یا فروش نیست؛ فقط یک توصیف است.

$$distance_w(t) = \frac{P_t}{SMA_w(t)} - 1 \quad (۱۸)$$

بیشینه و کمینه غلتان از قیمت مرجع در همان پنجره ساخته می‌شوند؛ این دو با بیشینه و کمینه کندل تفاوت دارند. در روزانه، مقادیر مطلق‌اند. در ساعتی، خروجی به قیمت جاری تقسیم و یک از آن کم می‌شود.

$$M_w(t) = \max(P_{t-w+1}, \dots, P_t), \quad m_w(t) = \min(P_{t-w+1}, \dots, P_t) \quad (۱۹)$$

۶.۶ نوسان تاریخی

نوسان ۵، ۱۰ و ۲۰ دوره‌ای، انحراف معیار نمونه‌ای بازده ساده است. `rolling.std()` در این کد با مخرج $w - 1$ کار می‌کند. این ویژگی بازده‌ها را سالانه نمی‌کند و از آن نمی‌توان مستقیم نوسان سالانه گرفت.

$$\bar{r}_w(t) = \frac{1}{w} \sum_{j=0}^{w-1} r_{t-j} \quad (۲۰)$$

$$\sigma_w(t) = \sqrt{\frac{\sum_{j=0}^{w-1} (r_{t-j} - \bar{r}_w(t))^2}{w-1}} \quad (۲۱)$$

استانداردسازی ویژگی‌ها که بعداً می‌آید، از برآورد واریانس با مخرج تعداد نمونه استفاده می‌کند. پس انحراف معیار غلتان و انحراف معیار مقیاس‌ساز دقیقاً قرارداد یکسانی ندارند؛ هر دو در جای خود درست‌اند.

۶.۷ ویژگی‌های حجم و دامنه

`volume_change` تغییر نسبی حجم نسبت به مشاهده قبل و `relative_volume_20` نسبت حجم جاری به میانگین ۲۰ مشاهده است. مقدار ۱ در حجم نسبی یعنی برابر با میانگین پنجره؛ مقدار ۲ یعنی دو برابر آن.

$$volumeChange_t = \frac{V_t}{V_{t-1}} - 1, \quad relativeVolume_t = \frac{V_t}{SMA_{20}(V)_t} \quad (۲۲)$$

ویژگی `range_to_close` دامنه کندل را نسبت به قیمت مرجع می‌سنجد. `return_times_volume` تعامل بازده و حجم را در روزانه وارد می‌کند؛ این ویژگی در مجموعه ساعتی حذف شده است.

$$rangeRatio_t = \frac{H_t - L_t}{P_t}, \quad interaction_t = r_t V_t \quad (۲۳)$$

در ساعتی، حجم خام با لگاریتم یک به علاوه حجم نمایش داده می‌شود. افزودن یک، مقدار صفر را از نظر لگاریتم قابل تعریف می‌کند؛ با این حال پاک‌سازی ساعتی در این پروژه حجم مثبت می‌خواهد.

$$\log Volume_t = \ln(1 + V_t) \quad (24)$$

۷ اندیکاتورهای فنی و قراردادهای دقیق آنها

۷.۱ هموارسازی وایلد

روش وایلد برای میانگین سود و زیان RSI و برای ATR استفاده می‌شود. ابتدا اولین پنجره کامل و متناهی پیدا می‌شود. میانگین ساده آن پنجره بذر است. سپس وزن داده جدید $1/n$ خواهد بود؛ در RSI و ATR مقدار $n = 14$ است.

$$W_{n-1} = \frac{1}{n} \sum_{j=0}^{n-1} z_j, \quad W_t = \frac{(n-1)W_{t-1} + z_t}{n} \quad (25)$$

در مقایسه با EMA با $\text{span}=14$ ، وزن جدید فرق می‌کند: برای وایلد یک چهاردهم و برای EMA دویازدهم است. دو خروجی را نباید به دلیل داشتن عدد ۱۴ معادل دانست. آغاز مجدد اندیکاتور پس از شکاف حل نشده نیز یک دوره گرم شدن جدید ایجاد می‌کند.

۷.۲ شاخص قدرت نسبی

RSI بزرگی افزایش‌ها و کاهش‌های اخیر را با هم مقایسه می‌کند. ابتدا تغییر قیمت محاسبه می‌شود؛ بخش مثبت آن سود و قدرمطلق بخش منفی زیان است. این‌ها سود و زیان حساب سرمایه‌گذار نیستند، بلکه تغییر عددی قیمت‌اند.

$$\Delta P_t = P_t - P_{t-1}, \quad G_t = \max(\Delta P_t, 0), \quad D_t = \max(-\Delta P_t, 0) \quad (26)$$

$$RS_t = \frac{W_{14}(G)_t}{W_{14}(D)_t}, \quad RSI_t = 100 - \frac{100}{1 + RS_t} \quad (27)$$

اگر میانگین زیان صفر و میانگین سود مثبت باشد، کد RSI را ۱۰۰ می‌گذارد. اگر هر دو صفر باشند، مقدار ۵۰ می‌شود. در حالت سود صفر و زیان مثبت، رابطه مقدار صفر می‌دهد. بنابراین سری کاملاً ثابت با مقدار تعریف نشده وارد مدل نمی‌شود.

مقادیر نزدیک ۷۰ و ۳۰ در بعضی کاربردهای تحلیل فنی به عنوان آستانه‌های توصیفی دیده می‌شوند، اما این پروژة قانون معامله بر اساس آن‌ها نمی‌سازد. RSI تنها یک ستون ورودی است و مدل باید ارتباط آن با هدف را از آموزش بیاموزد.

۷.۳ مکدی خط سیگنال و هیستوگرام

MACD اختلاف EMA سریع ۱۲ دوره‌ای و EMA کند ۲۶ دوره‌ای است. خط سیگنال EMA نه دوره‌ای MACD و هیستوگرام اختلاف دو خط است. مکدی تغییر فاصله دو مقیاس هموارسازی را توصیف می‌کند.

$$MACD_t = EMA_{12}(P)_t - EMA_{26}(P)_t \quad (28)$$

$$Signal_t = EMA_9(MACD)_t, \quad Histogram_t = MACD_t - Signal_t \quad (29)$$

در روزانه، مکدی و سیگنال واحد قیمت دارند. در ساعتی، هر سه به قیمت جاری تقسیم می‌شوند تا وابستگی مستقیم به سطح تاریخی قیمت کاهش یابد. حداقل پنجره ۲۶ و سپس سیگنال ۹، از علت‌های گرم شدن ویژگی‌هاست.

۷.۴ باندهای بولینگر

باند بالا و پایین از میانگین ۲۰ دوره‌ای و دو انحراف معیار نمونه‌ای قیمت ساخته می‌شوند. انحراف معیار این بخش روی قیمت است؛ با نوسان بازده در فصل قبل تفاوت دارد.

$$B_t^{upper} = SMA_{20}(P)_t + 2s_{20}(P)_t \quad (۳۰)$$

$$B_t^{lower} = SMA_{20}(P)_t - 2s_{20}(P)_t \quad (۳۱)$$

ویژگی bollinger_position در این پروژه فاصله قیمت از میانگین را بر دو انحراف معیار تقسیم می‌کند. روی میانگین، مقدار صفر؛ روی باند بالا، مقدار یک؛ روی باند پایین، مقدار منفی یک است. این تعریف با درصد باند رایج که روی باند پایین صفر و بالا یک دارد، یکسان نیست.

$$position_t = \frac{P_t - SMA_{20}(P)_t}{2s_{20}(P)_t} \quad (۳۲)$$

اگر پراکندگی صفر باشد و میانگین موجود باشد، موقعیت صفر می‌شود. در ساعتی، خود باند بالا و پایین بر قیمت جاری تقسیم می‌شوند، ولی bollinger_position همان تعریف بی‌بعد را حفظ می‌کند. این باندها در پروژه فاصله اطمینان پیش‌بینی آینده نیستند.

۷.۵ دامنه واقعی و میانگین دامنه واقعی

دامنه ساده یک کندل اختلاف بیشینه و کمینه است. دامنه واقعی، حرکت نسبت به قیمت مشاهده قبلی را هم لحاظ می‌کند؛ بنابراین شکاف بین دو مشاهده در آن منعکس می‌شود.

$$TR_t = \max(H_t - L_t, |H_t - P_{t-1}|, |L_t - P_{t-1}|) \quad (۳۳)$$

$$ATR_t = W_{14}(TR)_t \quad (۳۴)$$

مرجع قبلی در روزانه، پایانی رسمی تعدیل‌شده و در ساعتی، آخرین قیمت تعدیل‌شده است. برای اولین ردیف، دو عبارت وابسته به قیمت قبلی موجود نیستند و بیشینه قابل محاسبه از دامنه خود کندل گرفته می‌شود. ATR روزانه واحد قیمت دارد؛ در ساعتی به قیمت جاری تقسیم می‌شود. ATR جهت حرکت را نشان نمی‌دهد، فقط بزرگی دامنه را توصیف می‌کند.

۷.۶ تقسیم امن و ردیف‌های گرم‌شدن

safe_divide مخرج صفر را به مقدار مفقود تبدیل می‌کند. سپس تنها ردیف‌هایی باقی می‌مانند که همه ویژگی‌هایشان متناهی باشد. RSI ثابت و موقعیت بولینگر ثابت، قراردادهای خاص مستند شده دارند؛ سایر نسبت‌های با مخرج صفر خودکار به صفر تبدیل نمی‌شوند.

در آزمایش روزانه، ۳۳ ردیف برای گرم شدن یا نامتناهی بودن ویژگی‌ها حذف شده‌اند و ۱۰۰۴ ردیف قابل استفاده مانده است. در ساعتی، گرم شدن پس از قطعه‌های مختلف تکرار می‌شود؛ از ۴۲۷۳ کندل، ۴۰۰۹ ردیف ویژگی قابل استفاده باقی مانده است. شمار حذف شده برابر ۲۶۴ است و صرفاً یک گرم شدن ابتدای تاریخچه نیست.

۸ ویژگی‌های تقویمی و نمایش نسبی ساعتی

۸.۱ کدگذاری چرخه‌ای

اگر شماره روز هفته را یک عدد معمولی بدهیم، مدل ممکن است فاصله آخر هفته و اول هفته را بزرگ تصور کند. جفت سینوس و کسینوس هر مقدار را به نقطه‌ای روی دایره می‌برد. هر دو جزء لازم‌اند، چون یک سینوس به تنهایی بعضی موقعیت‌ها را یکسان نمایش می‌دهد.

$$\text{cyclicSin}(k) = \sin \frac{2\pi k}{m}, \quad \text{cyclicCos}(k) = \cos \frac{2\pi k}{m} \quad (۳۵)$$

برای روز هفته، دوره ۷ و شماره‌گذاری Pandas از دوشنبه با صفر است. ماه شمسی با شماره ۱ تا ۱۲ و دوره ۱۲ مصرف می‌شود. در ساعتی، ساعت شروع کندل با دوره ۲۴ کدگذاری می‌شود. این انتخاب، فاصله دوری را بازنمایی می‌کند؛ ترتیب واقعی روزهای معامله همچنان در داده حفظ می‌شود.

۸.۲ پایان ماه و فاصله زمانی

gregorian_month_end مشخص می‌کند آیا تاریخ، آخر ماه میلادی است. این اطلاعات از تقویم معلوم است. «آخرین جلسه واقعاً معامله شده ماه» ممکن است برای شناسایی به آینده نیاز داشته باشد؛ به همین دلیل آن متغیر وارد نشده است. ماه شمسی و پایان ماه میلادی دو ویژگی با تقویم متفاوت‌اند.

elapsed_days_feature فاصله روزانه مشاهدات را ثبت می‌کند. در روزانه فاصله روز تقویمی است؛ در ساعتی از فاصله ساعت تقسیم بر ۲۴ ساخته می‌شود و می‌تواند کسری باشد. elapsed_hours_feature فقط در ساعتی وجود دارد. این فاصله‌ها ویژگی کمکی‌اند؛ شمار گام‌های حافظه LSTM همچنان تعداد مشاهدات است.

۸.۳ تبدیل ویژگی‌های سطح قیمت

در ساعتی، میانگین‌ها، وقفه‌های قیمت و بیشینه و کمینه غلتان به قیمت جاری تقسیم و یک از آن‌ها کم می‌شود. مکدی، خط سیگنال، هیستوگرام، باندهای بولینگر و ATR فقط بر قیمت جاری تقسیم می‌شوند. بنابراین همه ستون‌های نسبی دقیقاً یک تبدیل مشترک ندارند.

$$relativeLevel_t = \frac{Q_t}{P_t} - 1, \quad normalizedIndicator_t = \frac{I_t}{P_t} \quad (36)$$

سه ویژگی `open_to_last`، `high_to_last` و `low_to_last` از نسبت قیمت‌های کندل به آخرین قیمت ساخته می‌شوند. در اینجا قیمت آخرین معامله کندل جاری پس از اتمام آن معلوم است. اگر پیش‌بینی پیش از اتمام کندل انجام شود، این قرارداد اطلاعاتی دیگر برقرار نیست.

۸.۴ معنی مقایسه پنج‌ویژگی ساعتی

در روزانه، مدل مقایسه‌ای OHLCV فقط قیمت بازشدن، بیشینه، کمینه، پایانی رسمی و حجم را می‌بیند. در ساعتی، پنج ورودی آن `open_to_last`، `high_to_last`، `low_to_last`، `return_1` و `log_volume` هستند. پس نام «OHLCV» در آزمایش ساعتی به نسخه نسبی و مختصر اطلاعات قیمت و حجم اشاره دارد، نه پنج ستون خام روزانه.

۹ تبدیل سری زمانی به نمونه یادگیری

۹.۱ پنجره لغزان و شکل تانسور

هر نمونه شامل چند مشاهده پشت‌سرهم است. ویژگی‌ها کنار هم ستون‌ها را می‌سازند و زمان روی محور دیگر حرکت می‌کند. مجموعه نمونه‌ها یک تانسور سه‌بعدی با ترتیب «نمونه، زمان، ویژگی» می‌سازد.

$$X \in R^{N \times L \times d}, \quad y \in R^{N \times 1} \quad (37)$$

در مدل منتخب روزانه، شکل هر نمونه ۶۰ در ۴۸ است؛ در ساعتی ۶۰ در ۴۹. طول پنجره تعداد واحدهای LSTM نیست. طول، تعداد گام زمانی ورودی است؛ تعداد واحدها، اندازه بردار حالت شبکه است.

مثال آموزشی: با طول سه و هدف مشاهده شماره چهار، قیمت‌ها و ویژگی‌های مشاهدات اول تا سوم ورودی‌اند و مشاهده چهارم برچسب است. با حرکت به هدف بعد، پنجره یک گام جلو می‌رود. پنجره‌های مجاور دو مشاهده مشترک دارند.

۹.۲ اهداف مشترک بین طول‌ها

برای مقایسه منصفانه، همه طول‌های نامزد باید روی یک فهرست هدف ارزیابی شوند. کد از بیشترین طول، یعنی ۶۰، برای یافتن اهداف قابل قبول استفاده می‌کند. مدل طول ۱۰ فقط آخرین ۱۰ ردیف همان سابقه معتبر را می‌بیند، ولی تاریخ هدفش با مدل طول ۶۰ یکی است.

شرط پذیرش آن است که شماره منبع در همه ۶۰ ورودی و خود هدف پیوسته باشد. این شرط از جهش پنهان ناشی از حذف ردیف‌ها جلوگیری می‌کند. کامل بودن فقط پنجره ورودی کافی نیست؛ فاصله آخرین ورودی تا هدف هم باید معتبر باشد.

$$n_{s+1} - n_s = 1, \quad s = t - 60, \dots, t - 1 \quad (38)$$

۹.۳ تقسیم زمانی

اهداف به ترتیب زمان با نسبت‌های ۷۰ درصد آموزش، ۱۵ درصد اعتبارسنجی و باقی‌مانده آزمون تقسیم می‌شوند. تعداد دو بخش اول با جزء صحیح محاسبه می‌شود؛ بنابراین بخش آزمون الزاماً دقیقاً ۱۵ درصد گردنشته نیست.

$$N_{train} = [0.70N], \quad N_{val} = [0.15N] \quad (39)$$

$$N_{test} = N - N_{train} - N_{val} \quad (40)$$

هر بخش باید دست‌کم ۲۰ هدف داشته باشد. تقسیم بر اساس تاریخ هدف است، نه جدا کردن سه جدول و ساخت پنجره درون هر جدول. به همین دلیل اولین هدف اعتبارسنجی می‌تواند از بخشی از تاریخچه آموزش به‌عنوان ورودی استفاده کند. این گذشته در زمان پیش‌بینی معلوم است و با نشت هدف آینده تفاوت دارد.

۹.۴ همپوشانی و اعتبار ارزیابی

همپوشانی پنجره‌ها باعث می‌شود خطاهای پیش‌بینی وابسته باشند. میانگین خطا برای گزارش توصیفی مفید است، ولی آزمون اختلاف دو مدل با فرض استقلال کامل همه نمونه‌ها می‌تواند بیش‌ازحد خوش‌بینانه باشد. پروژه آزمون معنی‌داری، بازنمونه‌گیری بلوکی یا ارزیابی چند برش زمانی اجرا نکرده است.

یک بهبود کوچک آزمون روی یک دوره را باید با این محدودیت خواند. برای آزمایش تازه می‌توان برش‌های زمانی از پیش تعیین‌شده و ارزیابی رو به جلو طراحی کرد؛ این‌ها پیشنهاد توسعه‌اند، نه بخشی از نتایج حاضر.

۱۰ استانداردسازی و جلوگیری از نشت اطلاعات

۱۰.۱ مقیاس ورودی‌ها

قیمت چند هزار ریالی، حجم چند میلیون سهمی و سینوس با دامنه یک، مقیاس‌های متفاوت دارند. بدون استانداردسازی، بزرگی عددی بعضی ستون‌ها می‌تواند یادگیری را دشوار کند. StandardScaler از هر ستون میانگین آموزش را کم می‌کند و نتیجه را بر انحراف معیار آموزش تقسیم می‌کند. [۳]

$$z_{i,j} = \frac{x_{i,j} - \mu_j}{s_j} \quad (41)$$

$$\mu_j = \frac{1}{M} \sum_{i=1}^M x_{i,j}, \quad s_j = \sqrt{\frac{1}{M} \sum_{i=1}^M (x_{i,j} - \mu_j)^2} \quad (42)$$

M شمار ردیف‌های یکتای ورودی آموزش است. مقیاس‌ساز روی ردیف‌های تکرارشده حاصل از باز کردن همه پنجره‌ها برازش نمی‌شود؛ ردیف‌هایی که در چند پنجره حضور دارند فقط یک بار در آمار مقیاس حساب می‌شوند. برای ستون با واریانس صفر، کتابخانه مقیاس مؤثر یک در نظر می‌گیرد.

۱۰.۲ مقیاس مستقل هدف

یک مقیاس ساز جدا روی برچسب‌های آموزش برآزش می‌شود. در روزانه، برچسب قیمت است؛ در ساعتی، بازده لگاریتمی. مدل خروجی استاندارد شده می‌دهد و برای گزارش باید تبدیل معکوس انجام شود.

$$\hat{y}_t = \mu_y + s_y \hat{z}_t \quad (43)$$

مثال آموزشی: اگر میانگین قیمت هدف آموزش ۲۰۰۰ و انحراف معیار ۱۰۰ باشد، خروجی استاندارد شده ۰/۵ به قیمت ۲۰۵۰ می‌رسد. اما اگر هدف، بازده باشد، همین محاسبه بازده را برمی‌گرداند و هنوز باید قیمت بازسازی شود.

۱۰.۳ انواع نشت اطلاعات

برآزش مقیاس ساز روی کل تاریخچه، میانگین آینده را وارد آموزش می‌کند. استفاده از میانگین متحرک مرکزی هم از مشاهده‌های بعدی استفاده می‌کند. انتخاب طول پنجره با کمترین خطای آزمون، آزمون را به ابزار تنظیم مدل تبدیل می‌کند. همه این کارها نتیجه ارزیابی را تغییر می‌دهند.

پروژه برای مقیاس و انتخاب مدل مرز آموزش و اعتبارسنجی را رعایت می‌کند؛ آزمون پس از انتخاب خوانده می‌شود. با این حال، محدودیت تعدیل گذشته‌نگر همچنان برقرار است. جلوگیری از نشت مقیاس ساز، آن محدودیت جداگانه را برطرف نمی‌کند.

۱۰.۴ وارون سازی هدف ساعتی

پس از بازگرداندن مقیاس بازده پیش‌بینی شده، قیمت قبلی در نمایی آن ضرب می‌شود. قیمت قبلی همان پیش‌بینی مبنای تداوم است.

$$\hat{P}_t = P_{t-1} \exp(\hat{\ell}_t) \quad (44)$$

اگر بازده پیش‌بینی شده در واحد اصلی صفر باشد، قیمت بعدی برابر قیمت قبلی می‌شود. اما خروجی استاندارد شده صفر معمولاً برابر میانگین بازده آموزش است، نه بازده صفر. این دو صفر را نباید در توضیح شبکه یا کد تست با هم اشتباه گرفت.

۱۱ شبکه عصبی بازگشتی و LSTM

۱۱.۱ نورون وزن و تابع فعال سازی

نورون یک ترکیب خطی از ورودی‌ها می‌سازد و سپس تابع فعال سازی را اعمال می‌کند. وزن‌ها شدت ارتباط را تعیین می‌کنند و بایاس اجازه می‌دهد خروجی فقط از صفر بودن ورودی‌ها تبعیت نکند. آموزش یعنی یافتن وزن‌ها و بایاس‌هایی که خطای هدف را کاهش دهند.

$$a = \varphi(Wx + b) \quad (45)$$

در یک شبکه بازگشتی ساده، حالت قبلی هم وارد محاسبه می‌شود. بدین ترتیب خلاصه‌ای از گذشته در حالت شبکه می‌ماند.

$$h_s = \tanh(Wx_s + Uh_{s-1} + b) \quad (46)$$

۱۱.۲ مشکل گرادیان در شبکه بازگشتی

در پس‌انتشار در طول زمان، مشتق از چندین تبدیل پشت‌سرهم عبور می‌کند. ضرب‌های مکرر کوچک می‌توانند گرادیان را محو کنند و ضرب‌های بزرگ می‌توانند آن را منفجر کنند. در نتیجه آموزش رابطه‌های دورتر از چند گام زمانی دشوار می‌شود.

LSTM مسیر حافظه سلولی و دروازه‌ها را اضافه می‌کند تا نگهداری یا تغییر اطلاعات بهتر کنترل شود. این طراحی مشکل را کاهش می‌دهد، اما تضمین نمی‌کند هر رابطه بلندمدت در داده کم یاد گرفته شود. طول پنجره ۶۰ یعنی مدل حداکثر ۶۰ گام ورودی همین نمونه را پردازش می‌کند.

۱۱.۳ حالت پنهان و حافظه سلولی

در LSTM دو بردار وجود دارد: h_s حالت پنهان خروجی و c_s حافظه سلولی. هر دو به اندازه تعداد واحدهای شبکه‌اند. ورودی یک گام x_s شامل همه ویژگی‌های همان مشاهده است. اندیس s در این فصل گام درون پنجره است، نه شماره هدف.

دروازه‌ها با سیگموئید مقدار بین صفر و یک می‌گیرند و نامزد حافظه با تانژانت هذلولوی مقدار بین منفی یک و یک تولید می‌کند. نماد $\odot$ ضرب مؤلفه‌به‌مؤلفه است؛ با ضرب ماتریسی وزن و ورودی فرق دارد. [۱]

$$\sigma(z) = \frac{1}{1+\exp(-z)}, \quad \tanh(z) = \frac{\exp(z)-\exp(-z)}{\exp(z)+\exp(-z)} \quad (47)$$

۱۱.۴ دروازه فراموشی

دروازه فراموشی تصمیم می‌گیرد چه سهمی از حافظه قبلی نگه داشته شود. مقدار نزدیک یک، مؤلفه مربوط را حفظ می‌کند و مقدار نزدیک صفر آن را کم‌رنگ می‌کند. «فراموشی» به معنی حذف رکورد داده نیست؛ وزن‌دهی درون حافظه شبکه است.

$$f_s = \sigma(W_f x_s + U_f h_{s-1} + b_f) \quad (48)$$

۱۱.۵ دروازه ورودی و نامزد حافظه

دروازه ورودی تعیین می‌کند چه مقدار اطلاعات تازه وارد حافظه شود. نامزد حافظه محتوای پیشنهادی را می‌سازد. این دو نقش جدا دارند: یک بردار محتوا پیشنهاد می‌دهد و دیگری مقدار ورود آن را کنترل می‌کند.

$$i_s = \sigma(W_i x_s + U_i h_{s-1} + b_i) \quad (49)$$

$$\tilde{c}_s = \tanh(W_c x_s + U_c h_{s-1} + b_c) \quad (50)$$

۱۱.۶ به روزرسانی سلول و دروازه خروجی

حافظه جدید از حافظه قدیم وزن دهی شده و محتوای تازه وزن دهی شده ساخته می شود. جمع این دو مسیر امکان نگهداری پیوسته بخشی از اطلاعات را فراهم می کند.

$$c_s = f_s \odot c_{s-1} + i_s \odot \tilde{c}_s \quad (51)$$

دروازه خروجی مشخص می کند چه بخشی از حافظه به حالت پنهان منتقل شود. خروجی حافظه ابتدا با تانژانت هذلولوی محدود می شود.

$$o_s = \sigma(W_o x_s + U_o h_{s-1} + b_o) \quad (52)$$

$$h_s = o_s \odot \tanh(c_s) \quad (53)$$

مثال آموزشی تک مؤلفه ای: اگر حافظه قبلی ۲، فراموشی ۰/۹، ورودی ۰/۲ و نامزد ۰/۵ باشد، حافظه تازه ۱/۹ است. حالت پنهان هنوز به دروازه خروجی وابسته است. این اعداد برای فهم رابطه اند و وزن های آموزش دیده پروژه نیستند.

۱۱.۷ ابعاد وزن ها و شمار پارامترها

با d ویژگی و u واحد، برای هر مسیر دروازه یا نامزد، ماتریس ورودی اندازه $d \times u$ ، ماتریس بازگشتی اندازه $u \times u$ و بایاس اندازه u دارد. چهار مسیر وجود دارد؛ بنابراین شمار پارامترهای لایه چنین است.

$$N_{LSTM} = 4u(d + u + 1) \quad (54)$$

لایه خروجی یک وزن برای هر واحد و یک بایاس دارد. Dropout وزن آموزش پذیر جدید ندارد.

$$N_{total} = 4u(d + u + 1) + u + 1 \quad (55)$$

برای مدل منتخب روزانه با ۴۸ ویژگی و ۶۴ واحد، لایه LSTM دارای ۲۸۹۲۸ و کل شبکه دارای ۲۸۹۹۳ پارامتر است. برای ساعتی با ۴۹ ویژگی و ۳۲ واحد، اعداد به ترتیب ۱۰۴۹۶ و ۱۰۵۲۹ هستند. طول پنجره شمار پارامترهای این معماری را عوض نمی کند، ولی هزینه محاسبه و الگوی اطلاعات را تغییر می دهد.

۱۱.۸ معماری واقعی پروژه

ترتیب لایه ها Dense → Dropout → LSTM → Input است. فقط یک لایه LSTM وجود دارد. خروجی همه گام ها به لایه بعد فرستاده نمی شود؛ پیش فرض return_sequences=False حالت خروجی آخر پنجره را می دهد. لایه Dense یک خروجی خطی تولید می کند. [۱]

شبکه در این پیاده‌سازی **stateful** نیست؛ حالت یک نمونه به عنوان حافظه پایدار نمونه بعد حمل نمی‌شود. گذشته از راه پنجره ورودی وارد هر نمونه می‌شود. **shuffle=False** ترتیب نمونه‌ها را در آموزش نگه می‌دارد، اما به خودی خود شبکه را دارای حافظه بین نمونه‌ها نمی‌کند.

پیش‌فرض‌های Keras شامل فعال‌سازی **tanh**، دروازه **sigmoid**، مقداردهی ورودی **glorot_uniform** و مقداردهی بازگشتی **orthogonal** است. بایاس دروازه فراموشی در آغاز به سمت نگهداری حافظه تنظیم می‌شود. نسخه محیط ذخیره‌شده، مرجع رفتار اجرایی دقیق است.

۱۲ آموزش تابع زیان و بهینه‌سازی

۱۲.۱ خطای مربعی میانگین

زیان آموزش **MSE** روی هدف استاندارد شده است. برای یک دسته با B نمونه، میانگین مربع تفاوت خروجی و برچسب محاسبه می‌شود. خطای بزرگ به دلیل مربع شدن وزن بیشتری می‌گیرد.

$$J(\theta) = \frac{1}{B} \sum_{i=1}^B (\hat{z}_i - z_i)^2 \quad (56)$$

θ مجموعه همه وزن‌ها و بایاس‌هاست. زیان روزانه روی قیمت استاندارد شده و زیان ساعتی روی بازده لگاریتمی استاندارد شده است. بنابراین مقایسه عدد خام زیان بین دو آزمایش معنی مشترک ریالی ندارد.

۱۲.۲ گرادیان و پس‌انتشار در طول زمان

گرادیان جهت تغییر زیان نسبت به هر پارامتر را نشان می‌دهد. محاسبه با باز کردن مسیر زمانی شبکه و قانون زنجیره انجام می‌شود؛ وزن‌های مشترک در همه گام‌ها از مجموع اثرهای زمانی به‌روزرسانی می‌شوند. Keras مشتق‌ها را خودکار محاسبه می‌کند.

$$g_k = \nabla_{\theta} J(\theta_{k-1}) \quad (57)$$

گرادیان نزولی ساده پارامتر را در جهت مخالف گرادیان تغییر می‌دهد. نرخ یادگیری اندازه گام را تعیین می‌کند. این رابطه مقدمه فهم Adam است؛ الگوریتم اجرایی پروژه Adam است، نه SCD ساده.

$$\theta_k = \theta_{k-1} - \eta g_k \quad (58)$$

۱۲.۳ الگوریتم Adam

Adam میانگین نمایی گرادیان و مربع گرادیان را نگه می‌دارد. اولی جهت‌های اخیر و دومی بزرگی مؤلفه‌ها را خلاصه می‌کند. برای هر مؤلفه پارامتر، اندازه گام به این اطلاعات وابسته می‌شود. [۲]

$$m_k = \beta_1 m_{k-1} + (1 - \beta_1) g_k \quad (59)$$

$$v_k = \beta_2 v_{k-1} + (1 - \beta_2) g_k^2 \quad (60)$$

چون این میانگین‌ها از صفر شروع می‌شوند، شکل نظری الگوریتم تصحیح بایاس دارد. در این فرمول مربع و تقسیم مؤلفه به مؤلفه هستند.

$$\hat{m}_k = \frac{m_k}{1 - \beta_1^k}, \quad \hat{v}_k = \frac{v_k}{1 - \beta_2^k} \quad (61)$$

$$\theta_k = \theta_{k-1} - \eta \frac{\hat{m}_k}{\sqrt{\hat{v}_k + \epsilon}} \quad (62)$$

کد فقط نرخ یادگیری ۰/۰۰۱ را صریح تعیین می‌کند. سایر تنظیمات از پیش‌فرض محیط Keras می‌آیند؛ مقادیر رایج این API برای دو ضریب ۰/۹ و ۰/۹۹۹ و برای epsilon مقدار ۰/۰۰۰۰۰۰۱ است. محل epsilon و جزئیات عددی پیاده‌سازی می‌تواند با نمایش نظری فرق داشته باشد. پروژه برش‌گرایان و برنامه تغییر نرخ یادگیری تعیین نکرده است. [۲]

۱۲.۴ Dropout و بیش‌برازش

بیش‌برازش زمانی رخ می‌دهد که مدل جزئیات داده آموزش را خوب یاد بگیرد، اما روی داده تازه ضعیف باشد. Dropout در زمان آموزش بعضی مؤلفه‌های حالت خروجی را تصادفی صفر می‌کند. با احتمال حذف ۰/۲، حدود یک‌پنجم مؤلفه‌ها در هر اعمال لایه حذف می‌شوند؛ این درصد ثابت دقیق برای هر نمونه نیست.

$$\tilde{h}_j = \frac{b_j h_j}{1 - p}, \quad b_j \sim \text{Bernoulli}(1 - p) \quad (63)$$

در استنتاج، لایه تصادفی غیرفعال است. Dropout این پروژه یک لایه مستقل پس از LSTM است؛ recurrent_dropout درون سلول تنظیم نشده و طبق پیش‌فرض صفر است. این تفاوت هم بر معنای منظم‌سازی و هم بر امکان استفاده از اجرای سریع GPU اثر دارد.

۱۲.۵ Epoch دسته و توقف زود هنگام

یک epoch عبور کامل از نمونه‌های آموزش است. دسته یا batch گروهی از نمونه‌هاست که گرایان آن‌ها برای یک به‌روزرسانی مصرف می‌شود. اندازه دسته روزانه ۳۲ و ساعتی ۶۴ است. آخرین دسته می‌تواند کوچک‌تر باشد. سقف آموزش هر نامزد ۱۰۰ epoch است؛ این سقف به معنی اجرای دقیق ۱۰۰ epoch برای همه مدل‌ها نیست. EarlyStopping زیان اعتبارسنجی را دنبال می‌کند. اگر بهبود رخ ندهد، پس از صبر ۱۰ epoch در روزانه یا ۱۲ در ساعتی آموزش متوقف می‌شود. restore_best_weights=True بهترین وزن‌های دیده‌شده را برمی‌گرداند. ModelCheckpoint نیز بهترین مدل اعتبارسنجی را ذخیره می‌کند.

CSVLogger روند هر epoch را ثبت می‌کند و TerminateOnNaN در برابر زیان نامعتبر محافظت می‌کند. پس از آموزش، تاریخچه زیان باید متناهی باشد. مقدار کمتر زیان آموزش به‌تنهایی دلیل انتخاب یک مدل نیست؛ معیار انتخاب نهایی نامزد، RMSE قیمت روی اعتبارسنجی است.

۱۲.۶ انتخاب epoch در برابر انتخاب معماری

برای هر نامزد، بهترین epoch با val_loss انتخاب می‌شود. سپس بین نامزدها، RMSE قیمت بازسازی شده معیار است. در روزانه، با یک مقیاس هدف ثابت، رتبه خطای قیمت و خطای استاندارد شده نزدیک به یک تبدیل مقیاس است. در ساعتی، تبدیل نمایی و ضرب در قیمت قبلی می‌تواند رتبه خطای بازده و قیمت را متفاوت کند. هیچ برازش دوباره مشترک روی آموزش و اعتبارسنجی پس از انتخاب انجام نشده است. مدل نهایی همان بهترین checkpoint نامزد منتخب است. این انتخاب، قرارداد ثابت آزمایش را روشن می‌کند و اجازه نمی‌دهد یک اجرای تازه ناگفته با نتیجه ذخیره شده مخلوط شود.

۱۳ مدل‌های مبنا و حذف گروه ویژگی

۱۳.۱ تداوم قیمت

پیش‌بینی تداوم یا Persistence قیمت مشاهده بعد را برابر آخرین قیمت معلوم می‌گذارد. این مدل پارامتر آموزش‌پذیر ندارد و برای قیمت‌های با ماندگاری زیاد می‌تواند قوی باشد.

$$\hat{P}_t^{persist} = P_{t-1} \quad (64)$$

در هدف ساعتی، بازده صفر دقیقاً همین مبنا را می‌سازد. اگر مدل پیچیده نتواند از تداوم بهتر شود، یافته پژوهش این است که پیچیدگی حاضر مزیت پیش‌بینی اندازه‌گیری شده‌ای نداشته است. این نتیجه درباره همین داده، هدف و روش آموزش است؛ نفی همه کاربردهای LSTM نیست.

۱۳.۲ رگرسیون Ridge

Ridge یک مدل خطی با جریمه مربعی وزن‌هاست. پنجره سه‌بعدی هر نمونه به یک بردار با Ld مؤلفه تخت می‌شود. ترتیب زمان و ویژگی در بردار باقی می‌ماند، اما مدل دیگر سازوکار حافظه بازگشتی ندارد. [۴]

$$\hat{z}_i = w^T v_i + b \quad (65)$$

$$J_{Ridge} = \sum_{i=1}^N (z_i - w^T v_i - b)^2 + \alpha \sum_{j=1}^{Ld} w_j^2 \quad (66)$$

این شکل با قرارداد زیان مجموع مربع‌ها در Ridge سازگار است. اگر به‌جای مجموع از میانگین استفاده شود، اثر عددی alpha تغییر می‌کند. بایاس در حالت معمول کتابخانه جریمه وزن‌های ویژگی را نمی‌گیرد. جریمه وزن‌ها را کوچک‌تر می‌کند و در حضور همبستگی زیاد ستون‌ها به پایداری کمک می‌کند، ولی خطی بودن مدل را عوض نمی‌کند. alpha از میان ۰٫۱، ۱ و ۱۰ با RMSE اعتبارسنجی انتخاب می‌شود؛ در هر دو اجرای ذخیره شده، مقدار ۱۰ انتخاب شده است. طول پنجره آن همان طول منتخب LSTM است. برای تفسیر، در روزانه بردار منتخب ۲۸۸۰ مؤلفه و در ساعتی ۲۹۴۰ مؤلفه دارد؛ تعداد نمونه آموزش در روزانه فقط ۶۱۸ است. منظم‌سازی در چنین نسبت ابعادی اهمیت دارد.

۱۳.۳ حذف گروه ویژگی و مقایسه OHLCV

آزمایش حذف ویژگی یا Ablation می‌پرسد آیا ورودی‌های افزوده، در همین معماری فایده داشته‌اند. مدل OHLCV با طول و تعداد واحدهای منتخبِ مدل کامل آموزش می‌بیند، ولی پنج ویژگی پایه دارد. تاریخ هدف‌ها، معماری و روش ارزیابی مشترک‌اند و مقیاس‌سازهای آن مستقل‌اند.

این مقایسه نشان نمی‌دهد کدام ستون به‌تنهایی مفید یا مضر بوده است. برای چنین ادعایی باید حذف گروه‌های کوچک‌تر، اهمیت ویژگی یا تحلیل حساسیت طراحی شود. همچنین نتیجه بهتر یک مدل جانبی روی آزمون نباید پس از دیدن آزمون بهانه انتخاب نهایی تازه شود.

۱۳.۴ جست‌وجوی محدود ابرپارامترها

ابرپارامترها تنظیم‌هایی‌اند که پیش از یادگیری وزن‌ها انتخاب می‌شوند. روزانه سه طول ۱۰، ۳۰، ۶۰ را با دو عرض ۳۲ و ۶۴ ترکیب می‌کند؛ ساعتی طول‌های ۱۲، ۲۴، ۶۰ با همان دو عرض دارد. برای هر آزمایش شش نامزد LSTM کامل وجود دارد.

این روش جست‌وجوی شبکه‌ای کوچک است. dropout، نرخ یادگیری و اندازه دسته در این جست‌وجو تغییر نمی‌کنند. تعداد کم نامزدها زمان اجرا را محدود می‌کند، اما اثبات نمی‌کند بهترین معماری ممکن پیدا شده است. افزایش جست‌وجو نیز به داده اعتبارسنجی و طرح ارزیابی تازه نیاز دارد.

۱۴ ارزیابی خطا و نمودارها

۱۴.۱ قرارداد خطا و هم‌ترازی

در evaluation.py خطا «پیش‌بینی منهای واقعیت» است. مثبت بودن آن یعنی بیش‌برآوردی و منفی بودن آن یعنی کم‌برآوردی. در نمودار residual نیز همین قرارداد استفاده می‌شود. تعریف دیگری از residual ممکن است علامت را برعکس کند؛ برای تحلیل باید قرارداد همین پروژه را نگه داشت.

$$e_i = \hat{P}_i - P_i \quad (۶۷)$$

پیش از محاسبه، شکل، ترتیب زمانی و متناهی بودن مقادیر بررسی می‌شود. مقایسه دو آرایه با طول برابر اما تاریخ‌های متفاوت معتبر نیست. خروجی CSV تاریخ هدف، مقدار واقعی و پیش‌بینی همه مدل‌ها را در یک ردیف قرار می‌دهد.

۱۴.۲ MAE و MSE

MAE میانگین قدرمطلق خطاست. مقدار آن در واحد قیمت است و فهم مستقیم دارد. MSE مربع خطاها را میانگین می‌گیرد؛ واحد آن مربع ریال است و به خطاهای بزرگ حساس‌تر است.

$$MAE = \frac{1}{N} \sum_{i=1}^N |e_i|, \quad MSE = \frac{1}{N} \sum_{i=1}^N e_i^2 \quad (۶۸)$$

۱۴.۳ MAPE و RMSE

RMSE ریشه MSE است و دوباره واحد قیمت می‌گیرد. MAPE میانگین خطای نسبیِ قدرمطلق را به درصد گزارش می‌کند. هر معیار بعد متفاوتی از کیفیت را نشان می‌دهد و رتبه مدل‌ها می‌تواند بین آن‌ها فرق کند.

$$RMSE = \sqrt{MSE} \quad (۶۹)$$

$$MAPE = \frac{100}{N_+} \sum_{i:P_i \neq 0} \left| \frac{e_i}{P_i} \right| \quad (۷۰)$$

N_+ تعداد هدف‌های غیرصفر است. در کد، هدف صفر از MAPE کنار گذاشته می‌شود و اگر هیچ هدف غیرصفری نباشد، نتیجه تهی است. پاک‌سازی بازار در این پروژه قیمت مثبت می‌خواهد؛ بنابراین در داده اصلی همه هدف‌ها در مخرج MAPE شرکت می‌کنند. قیمت‌های بسیار کوچک می‌توانند MAPE را نامتناسب بزرگ کنند.

۱۴.۴ مثال محاسبه معیارها

برای قیمت‌های واقعی ۱۰۰ و ۲۰۰ و پیش‌بینی‌های ۱۱۰ و ۱۸۰، خطاها ۱۰ و منفی ۲۰ هستند. MAE برابر ۱۵، MSE برابر ۲۵۰، RMSE حدود ۱۵/۸۱۱ و MAPE برابر ۱۰ درصد می‌شود. این مثال با آزمون واحد معیارها در پروژه نیز سازگار است.

$$MAE = \frac{10+20}{2} = 15, \quad RMSE = \sqrt{250} \approx 15.811 \quad (۷۱)$$

عدد RMSE را نباید «میانگین اختلاف معمول مستقیم» معرفی کرد؛ MAE آن مفهوم را مستقیم‌تر نشان می‌دهد. RMSE به خطاهای بزرگ وزن بیشتری می‌دهد و به همین دلیل مدل با چند خطای شدید می‌تواند RMSE بدتری داشته باشد، حتی اگر MAE آن نزدیک باشد.

۱۴.۵ بهبود نسبی نسبت به تداوم

کد درصد بهبود را از نسبت RMSE مدل به تداوم محاسبه می‌کند. عدد مثبت یعنی خطای کمتر و عدد منفی یعنی خطای بیشتر. اگر RMSE مبنا صفر باشد، این نسبت تعریف ندارد.

$$Improvement = 100 \left(1 - \frac{RMSE_{model}}{RMSE_{persist}} \right) \quad (۷۲)$$

بهبود منفی ۶۶۸ درصد به معنی «دقت منفی» نیست؛ مدل حدود ۷/۶۸ برابر مبنا RMSE دارد. برای جلوگیری از سوءبرداشت، کنار درصد، نسبت یا مقدار خام معیار هم گزارش می‌شود.

۱۴.۶ خواندن نمودارها

نمودار تاریخچه قیمت، تغییر سطح سری را نشان می‌دهد. نمودار آموزش و اعتبارسنجی روند زیان استاندارد شده را نمایش می‌دهد؛ فاصله رو به افزایش بین این دو می‌تواند نشانه بیش‌برازش باشد، ولی باید همراه دوره داده و رفتار checkpoint خوانده شود.

نمودار پیش‌بینی، همه مدل‌ها و واقعیت را روی تاریخ‌های مشترک قرار می‌دهد. نمودار خطای زمانی نشان می‌دهد آیا خطا در یک بخشِ آزمون تجمع یافته است. هیستوگرام خطا پراکندگی و جهت‌داری را خلاصه می‌کند؛ به‌تنهایی استقلال یا نرمال بودن خطاها را ثابت نمی‌کند. شکل‌ها در پروژه با PNG، PDF و SVG ذخیره می‌شوند تا کیفیت نمایش و چاپ حفظ شود.

۱۵ آزمایش روزانه و نتایج واقعی

۱۵.۱ داده و تقسیم‌ها

بازهٔ روزانه از ۲۶ سپتامبر ۲۰۲۱ تا ۲۶ سپتامبر ۲۰۲۶ در مجموعهٔ ثابت ثبت شده است. از ۱۰۳۸ ردیف خام، ۱۰۳۷ معتبر و یک ردیف قرنطینه باقی مانده‌اند. پس از ساخت ویژگی‌ها، ۱۰۰۴ ردیف قابل استفاده‌اند. به علت شرط پیوستگی و حداقل سابقه، تعداد هدف‌ها ۸۸۴ است؛ این عدد را نباید صرفاً با کم کردن ۶۰ از ۱۰۰۴ محاسبه کرد.

بخش	شمار هدف	نخستین تاریخ	آخرین تاریخ
آموزش	۶۱۸	2022-02-07	2024-11-06
اعتبارسنجی	۱۳۲	2024-11-09	2025-06-08
آزمون	۱۳۴	2025-06-09	2026-09-26

۱۵.۲ معماری و انتخاب

مدل منتخب طول ۶۰ و ۶۴ واحد دارد. RMSE اعتبارسنجی آن ۳۲۴٫۰۵۴ ریال تعدیل‌شده است. dropout برابر ۰٫۲، نرخ Adam برابر ۰٫۰۰۱، دسته ۳۲، سقف epoch برابر ۱۰۰ و صبر توقف ۱۰ است. بذر تصادفی ۴۲ ثبت شده است. آموزش ذخیره‌شده روی NVIDIA A100-SXM4-80GB انجام شده است. هر دو قالب ذخیرهٔ مدل دوباره بارگذاری شده‌اند و پیش‌بینی‌های ۱۳۴ هدف آزمون بازتولید شده است. این بررسی سلامت ذخیره‌سازی و تبدیل مقیاس را تأیید می‌کند؛ برتری علمی مدل را تأیید نمی‌کند.

۱۵.۳ جدول نتیجهٔ آزمون روزانه

در جدول، MAE و RMSE بر حسب ریال تعدیل‌شده و MAPE بر حسب درصد هستند. اعداد برای نمایش تا سه رقم اعشار گرد شده‌اند؛ فایل JSON مقدار دقیق‌تر را نگه می‌دارد.

مدل	MAE	RMSE	MAPE
LSTM کامل	۳۳۵٫۵۷۴	۴۶۷٫۰۷۱	۱۱٫۷۵۶

مدل	MAE	RMSE	MAPE
تداوم قیمت	۵۲,۱۲۵	۶۰,۸۰۱	۱,۹۶۶
Ridge	۱۸۷,۹۴۲	۲۶۱,۷۴۶	۷,۰۰۰
LSTM با OHLCV	۲۸۳,۳۲۵	۳۹۰,۷۷۷	۹,۹۰۰

مدل کامل در هر سه معیار از تداوم و از LSTM مختصر ضعیف‌تر است. RMSE آن حدود ۷/۶۸ برابر تداوم است. نمودار آزمون، کم‌برآوردی قابل توجه در بخش‌های انتهایی را نشان می‌دهد. نتیجه ثبت‌شده مزیت پیش‌بینی برای معماری کامل روزانه نشان نمی‌دهد.

اضافه کردن اندیکاتورهای بیشتر در این اجرا، خطا را کم نکرده است. علت قطعی از این جدول مشخص نمی‌شود؛ محدودیت تعداد نمونه، یادگیری سطح قیمت و تغییر توزیع از احتمال‌هایی هستند که به آزمایش جدا نیاز دارند. پس از دیدن آزمون، تنظیم تازه‌ای برای بهتر کردن همین نتیجه انجام نشده است.

۱۶ آزمایش ساعتی و نتایج واقعی

۱۶.۱ ساخت کندل از معاملات برگشتی

بازه ساعتی از ۲ اکتبر ۲۰۲۱ ساعت ۹ تا ۳۰ سپتامبر ۲۰۲۶ ساعت ۱۲ است. کندل‌ها با بازه‌های یک‌ساعتی بسته از چپ و برچسب از چپ ساخته می‌شوند؛ برچسب ساعت ۹، شروع بازه را نشان می‌دهد و اطلاعات کامل آن پس از پایان بازه موجود است.

برای هر بازه، اولین قیمت باز شدن، بیشترین قیمت بیشینه، کمترین قیمت کمینه و آخرین قیمت، پایان کندل است. حجم جمع و تعداد ثبت‌های برگشتی شمرده می‌شود. فقط بازه‌های دارای معامله نگه داشته می‌شوند. مرتب‌سازی پایدار باعث می‌شود برای زمان‌های برابر، ترتیب برگشتی منبع در تعیین اولین و آخرین حفظ شود. تعداد ۴۲۷۳ کندل از ۱۰۲۵ فایل معاملات خام ذخیره‌شده بازسازی و با خروجی تطبیق داده شده است. این تطبیق نشان می‌دهد تجمیع نسبت به معاملات برگشتی درست است؛ کامل بودن همه معاملات واقعی بازار را به‌تنهایی اثبات نمی‌کند.

۱۶.۲ شکاف‌ها و ساعت‌های دیرتر

۱۵ تاریخ در پوشش دریافت حل‌نشده باقی مانده‌اند. اندیکاتورها پس از آن‌ها از نو شروع می‌شوند و هیچ پنجره ورودی و هدف از این شکاف‌ها عبور نمی‌کند. تعطیلی عادی معلوم حفظ می‌شود. ۲۳۶ کندل با زمان شروع ساعت ۱۳ یا بعدتر هم در داده مانده‌اند، چون نوع جلسه منبع آن‌ها مستقلاً تأیید نشده است.

حذف این کندل‌ها بدون بررسی منبع، تصمیمی دلخواه درباره داده می‌شد. گزارش حاضر وجودشان را صریح نگه می‌دارد. زمان‌های ذخیره‌شده محلی‌اند و تبدیل منطقه زمانی روی آن‌ها انجام نشده است.

۱۶.۳ داده و ویژگی و تقسیم‌ها

پس از گرم‌شدن قطعه‌ها و حذف مقادیر نامتناهی، ۴۰۰۹ ردیف ویژگی و ۳۵۵۸ هدف مشترک وجود دارد. هر ردیف ۴۹ ویژگی دارد. پنجره‌های ۱۲، ۲۴ و ۶۰ مشاهده با عرض‌های ۳۲ و ۶۴ روی این اهداف مشترک مقایسه شده‌اند.

بخش	شمار هدف	نخستین زمان	آخرین زمان
آموزش	۲۴۹۰	2021-11-03 12:00	2024-09-01 11:00
اعتبارسنجی	۵۳۳	2024-09-01 12:00	2025-05-03 12:00
آزمون	۵۳۵	2025-05-04 09:00	2026-09-30 12:00

۱۶.۴ آموزش انتخاب و بازتولید

نامزد منتخب ۶۰ کندل و ۳۲ واحد دارد؛ RMSE اعتبارسنجی ۲۹/۲۱۰ ریال تعدیل‌شده است. هدف `log_return`، دسته ۶۴ و صبر توقف ۱۲ است. `dropout` و نرخ یادگیری مانند روزانه‌اند. پیکربندی آموزش، GPU قابل مشاهده برای TensorFlow از خانواده A100 می‌خواهد و در نبود آن آموزش به CPU برمی‌گردد.

اجرای ثبت‌شده از NVIDIA A100-SXM4-40GB با TensorFlow نسخه 2.20.0 و Python نسخه 3.13.15 استفاده کرده است. فرمت‌های منتخب `keras` و `h5`. دوباره بارگذاری و همه ۵۳۵ پیش‌بینی آزمون بازتولید شده‌اند. بررسی محلی مستقل نیز سه بخش و چهار مجموعه معیار را بازتولید کرده است.

بین CPU و A100 برای مدل OHLCV اختلاف حداکثر ۰/۰۰۹۳۷۷ ریال ثبت شده که در تلورانس صریح ۰/۰۱ ریال قرار دارد. اختلاف کوچک‌میز شناور با خرابی مدل یکی نیست؛ پیش‌بینی‌های اصلی و معیارهای آزمون ذخیره‌شده تغییر نکرده‌اند.

۱۶.۵ جدول نتیجه آزمون ساعتی

مدل	MAE	RMSE	MAPE
LSTM کامل	۲۲/۶۴۶	۳۳/۰۴۹	۰/۹۳۵
تداوم قیمت	۲۰/۳۲۲	۳۲/۷۹۳	۰/۸۳۲

مدل	MAE	RMSE	MAPE
Ridge	۵۲,۳۷۳	۹۹,۱۳۲	۲,۱۴۹
OHLCV با LSTM	۲۲,۴۵۲	۳۲,۱۴۳	۰,۹۲۳

RMSE مدل کامل حدود ۰,۷۸ درصد بدتر از تداوم است. مدل OHLCV حدود ۱,۹۸ درصد RMSE کمتری از تداوم دارد، اما MAE و MAPE آن بیشتر است. بنابراین یک مدل در همه معیارها برنده نیست. این یافته جانبی بدون تبدیل آزمون به ابزار انتخاب مدل گزارش می‌شود.

۱۶.۶ مقایسه درست دو آزمایش

کوچک‌تر بودن خطای ریالی ساعتی نسبت به روزانه به خودی خود نشان نمی‌دهد دقت الگوریتم افزایش یافته است. هدف، فاصله زمانی، دوره آزمون و توزیع قیمت متفاوت‌اند. برای نتیجه‌گیری درباره آزمایش ساعتی، مقایسه همان‌زمان آن با تداوم، Ridge و OHLCV معتبرتر است.

داده ساعتی مشاهدات بیشتری دارد، ولی کندل‌های هم‌جلسه و پنجره‌های همپوشان مستقل نیستند. تغییر هدف به بازده و نسبی شدن ورودی‌ها هم‌زمان با تغییر بسامد رخ داده‌اند؛ سهم هر تغییر از جدول حاضر جداشدنی نیست.

۱۷ ذخیره‌سازی بازتولید و آزمون‌های نرم‌افزار

۱۷.۱ مجموعه ثابت و اثرانگشت فایل

Snapshot نسخه ثابت داده برای یک آزمایش است. فایل manifest.json دوره، منبع، قرارداد زمانی و SHA-256 فایل‌ها را نگه می‌دارد. SHA-256 از محتوای فایل یک اثرانگشت می‌سازد؛ تغییر حتی یک بایت معمولاً اثرانگشت را عوض می‌کند. این کنترل تغییر فایل را آشکار می‌کند، اما درست بودن واقعیت بازار را ثابت نمی‌کند.

اثر اجرای پژوهش از تنظیمات، اثر داده و اثر کد ساخته می‌شود. به همین دلیل تغییر طول پنجره، فایل داده یا کد می‌تواند مسیر اجرای جدید بسازد. فایل JSON ابتدا در فایل موقت نوشته و سپس جایگزین می‌شود تا خروجی نیمه‌نوشته کمتر باقی بماند.

۱۷.۲ چه چیزهایی همراه مدل لازم‌اند

مدل به‌تنهایی کافی نیست. ترتیب ویژگی‌ها، مقیاس‌ساز ورودی، مقیاس‌ساز هدف، طول پنجره، تعریف هدف و مبنای تعدیل برای بازسازی پیش‌بینی لازم‌اند. جابه‌جا کردن دو ستون با شکل یکسان می‌تواند بدون خطای نرم‌افزاری، پیش‌بینی غلط تولید کند.

فایل یا گروه	نقش در بازتولید
feature_order.json	ترتیب دقیق ستون‌های ورودی
scalers.joblib	پارامترهای استانداردسازی ورودی و هدف
model_metadata.json	معماری منتخب، هدف و مرزهای زمانی
sequences_*.npz	نمونه‌ها، هدف‌ها، زمان‌ها و موقعیت منبع
model.h5 و model.keras	وزن‌ها و ساختار مدل منتخب
test_predictions.csv	خروجی هم‌تراز همه مدل‌ها
test_metrics.json	معیارهای دقیق واحد اصلی
epochs.csv و history.json	روند آموزش و اعتبارسنجی
environment.json	نسخه‌ها، سخت‌افزار و بذر تصادفی

۱۷.۳ بذر تصادفی و سخت‌افزار

بذر ۴۲ برای Python، NumPy و TensorFlow تنظیم می‌شود. در صورت پشتیبانی، حالت اجرای قطعی نیز فعال می‌شود. با این حال، نسخه کتابخانه، ترتیب عملیات موازی و سخت‌افزار می‌توانند اختلاف عددی جزئی بسازند. «بازتولیدپذیر» در اینجا باید همراه تلورانس و محیط ثبت‌شده خوانده شود.

GPU سرعت عملیات تانسوری را افزایش می‌دهد؛ تعداد بیشتر پردازنده یا استفاده از A100 مزیت پیش‌بینی ایجاد نمی‌کند. تنظیم محدود thread pool و prefetch(1) در دیتاست‌ها برای کنترل منابع اجرای CPU است و معنای مالی هدف را تغییر نمی‌دهد.

۱۷.۴ آزمون‌هایی که قراردادها را بررسی می‌کنند

آزمون‌ها کنترل می‌کنند که تغییر آینده روی مبنای تعدیل ثابت، ویژگی‌های گذشته را عوض نکند؛ مقیاس‌ساز آموزش با مقادیر آینده تغییر نکند؛ RSI سری ثابت ۵۰ و موقعیت بولینگر صفر شود؛ بذر وایلدِر درست باشد؛ و تاریخ‌های هدف بین طول‌ها مشترک بمانند.

آزمون ساعتی یکنواخت بودن ضریب تعدیل در یک روز، عبور نکردن پنجره از شکاف حل‌نشده و بازسازی قیمت از بازده را بررسی می‌کند. آزمون بارگذاری، هم‌ترازی تاریخ و برابری پیش‌بینی ذخیره‌شده و بازساخته‌شده را می‌سنجد. این آزمون‌ها صحت قرارداد اجرایی را بررسی می‌کنند؛ دقت آینده بازار را تضمین نمی‌کنند.

۱۷.۵ کتابخانه‌ها و ابزارهای اجرا

NumPy محاسبات آرایه و تانسور، Pandas جدول و زمان، scikit-learn استانداردسازی و Ridge و TensorFlow/Keras شبکه عصبی را اجرا می‌کنند. Matplotlib نمودار می‌سازد، jdatetime تبدیل تاریخ را انجام می‌دهد و joblib برخی اشیای مدل و مقیاس‌ساز را ذخیره می‌کند. CLI مراحل ورود، دریافت، آماده‌سازی، آموزش و بررسی را از هم جدا می‌کند.

نوت‌بوک‌های Colab رابط اجرای همان منطق‌اند. ZIP خروجی، داده ثابت و اجرای پژوهش را همراه اثرانگشت بسته‌بندی می‌کند. پوشه نتایج ساعتی نام‌های توصیفی برای نامزدها دارد و نگاشت نام‌های اصلی را نگه می‌دارد؛ نام مرتب‌تر پوشه نباید با آموزش تازه اشتباه گرفته شود.

۱۸ مدل‌های آموزشی مکمل در یادداشت TSA

۱۸.۱ حدود این فصل

یادداشت Time_Series_Analysis_(TSA).md علاوه بر مفاهیم پایه، ARIMA و هموارسازی نمایی را معرفی می‌کند. این فصل برای کامل کردن مفاهیم موجود در پروژه است. مسیر آموزشی ذخیره‌شده این مدل‌ها را برازش یا با LSTM مقایسه نکرده است؛ در جدول نتیجه نباید خطایی برای آن‌ها اضافه کرد.

۱۸.۲ خودرگرسیون و تفاضل‌گیری

مدل خودرگرسیون AR مقدار جاری را از ترکیب خطی مقادیر گذشته می‌سازد. درجه p تعداد وقفه‌های آن است. خطای تازه با ε_t نمایش داده می‌شود.

$$Y_t = c + \sum_{j=1}^p \varphi_j Y_{t-j} + \varepsilon_t \quad (۷۳)$$

تفاضل‌گیری تغییر مشاهده نسبت به قبل را می‌گیرد و می‌تواند بخشی از روند را حذف کند. تفاضل مرتبه دو یعنی تفاضل دوباره سری تفاضل‌گرفته‌شده.

$$\Delta Y_t = Y_t - Y_{t-1}, \quad \Delta^2 Y_t = Y_t - 2Y_{t-1} + Y_{t-2} \quad (۷۴)$$

هدف بازده لگاریتمی ساعتی را می‌توان تفاضل لگاریتم قیمت دانست، ولی شبکه ساعتی ARIMA نیست. یک تبدیل مشترک داده، مدل‌ها را از نظر الگوریتم یکسان نمی‌کند.

۱۸.۳ میانگین متحرک در مدل MA

در مدل آماری MA، مقدار سری از خطاهای جاری و گذشته ساخته می‌شود. این «میانگین متحرک» با SMA اندیکاتور قیمت فرق دارد؛ SMA روی مقدارهای مشاهده‌شده میانگین می‌گیرد، ولی MA روی شوک‌های مدل رابطه می‌سازد.

$$Y_t = \mu + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j} \quad (75)$$

۱۸.۴ ARIMA و SARIMA

ARIMA سه جزء دارد: وقفه خودرگرسیون با درجه p ، تفاضل‌گیری با مرتبه d و خطاهای گذشته با درجه q . اگر $Z_t = \Delta^d Y_t$ باشد، رابطه غیرفصلی به این صورت نوشته می‌شود. [۸]

$$Z_t = c + \sum_{j=1}^p \varphi_j Z_{t-j} + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j} \quad (76)$$

SARIMA جزءهای فصلی با دوره معلوم را اضافه می‌کند و معمولاً با درجات فصلی P, D, Q و دوره m توصیف می‌شود. انتخاب درجات به تشخیص و ارزیابی نیاز دارد. در پروژه برای ARIMA یا SARIMA پارامتر برآورد شده و نتیجه ذخیره شده وجود ندارد.

۱۸.۵ هموارسازی نمایی ساده و هولت

هموارسازی نمایی ساده سطح سری را با وزن بیشتر برای مقدار جدید به روز می‌کند. پیش‌بینی تک‌گامی سطح هموار شده فعلی است. این روش برای سری بدون روند و فصل‌مندی مدل شده یک مبنای آموزشی است.

$$l_t = \alpha Y_t + (1 - \alpha)l_{t-1}, \quad \hat{Y}_{t+1} = l_t \quad (77)$$

در روش هولت، علاوه بر سطح l_t ، روند b_t به روز می‌شود. پارامترهای هموارسازی سطح و روند جدا هستند.

$$l_t = \alpha Y_t + (1 - \alpha)(l_{t-1} + b_{t-1}) \quad (78)$$

$$b_t = \beta(l_t - l_{t-1}) + (1 - \beta)b_{t-1} \quad (79)$$

$$\hat{Y}_{t+h} = l_t + hb_t \quad (80)$$

هولت وینترز جزء فصلی را هم اضافه می‌کند. در نسخه جمعی، اثر فصل جدا از سطح جمع می‌شود؛ در نسخه ضربی، اندازه فصل با سطح نسبت دارد. این خانواده، روند و فصل را صریح مدل می‌کند، در حالی که LSTM رابطه را از ویژگی‌ها و توالی‌ها یاد می‌گیرد. [۷]

برای نسخه جمعی، m طول فصل و s_t اثر فصلی است. مشاهده بدون اثر فصل برای به‌روزرسانی سطح مصرف می‌شود و روند با رابطه هولت به روز می‌شود. یک صورت متداول برای سطح و فصل چنین است.

$$l_t = \alpha(Y_t - s_{t-m}) + (1 - \alpha)(l_{t-1} + b_{t-1}) \quad (81)$$

$$s_t = \gamma(Y_t - l_{t-1} - b_{t-1}) + (1 - \gamma)s_{t-m} \quad (82)$$

در پیش‌بینی، آخرین مؤلفه فصلی متناظر با افق آینده استفاده می‌شود. k تعداد چرخه‌های کامل قبل از آن موقعیت است؛ این فرمول یک مقدار فصل را از آینده نمی‌خواند.

$$k = \lfloor (h-1)/m \rfloor, \hat{Y}_{t+h} = l_t + hb_t + s_{t+h-m(k+1)} \quad (۸۳)$$

در صورت ضربی، مشاهده برای حذف فصل بر ضریب فصلی تقسیم می‌شود و پیش‌بینی دوباره در آن ضریب ضرب می‌شود. مقداردهی اولیه سطح، روند و فصل و حدود پارامترها هم بخشی از برازش‌اند؛ این پروژه برای آن‌ها عدد اجرایی تعیین نکرده است.

$$l_t = \alpha \frac{Y_t}{s_{t-m}} + (1 - \alpha)(l_{t-1} + b_{t-1}) \quad (۸۴)$$

$$s_t = \gamma \frac{Y_t}{l_{t-1} + b_{t-1}} + (1 - \gamma)s_{t-m} \quad (۸۵)$$

$$\hat{Y}_{t+h} = (l_t + hb_t)s_{t+h-m(k+1)} \quad (۸۶)$$

۱۸.۶ کتابخانه تحلیل آماری

statsmodels برای مدل‌هایی مانند ARIMA و هموارسازی نمایی کاربرد دارد، اما مسیر اصلی این پروژه از scikit-learn برای Ridge و از TensorFlow برای LSTM استفاده می‌کند. Pandas ابزار زمان و محاسبه rolling است؛ خود Pandas الگوریتم آموزش ARIMA را اجرا نمی‌کند.

۱۹ واژه‌نامه کاربردی و دام‌های تفسیر

۱۹.۱ واژه‌نامه

اصطلاح	معنی در این پروژه
Feature	ورودی عددی ساخته‌شده تا پایان مشاهده
Label یا Target	مقدار مشاهده بعد که مدل باید یاد بگیرد
Horizon	یک گام در شمار مشاهدات معتبر
Lookback	طول سابقه ورودی هر نمونه
Warm up	ردیف‌های لازم برای شکل‌گیری اندیکاتورها
Validation	دوره انتخاب معماری و تنظیمات
Holdout Test	دوره گزارش نهایی پس از انتخاب
Checkpoint	مدل ذخیره‌شده در بهترین epoch
Scaling	تبدیل با میانگین و مقیاس آموزش

اصطلاح	معنی در این پروژه
Leakage	استفاده ناخواسته از اطلاعات خارج از مرز مجاز
Ablation	مقایسه پس از حذف گروهی از ورودی‌ها
Residual	پیش‌بینی منهای قیمت واقعی در این کد
Retrospective	مطالعه روی تاریخچه با مبنای تعدیل بعداً معلوم
Point in time	استفاده فقط از اطلاعات معلوم در همان زمان تاریخی
Provenance	سابقه منبع، ورود و تغییرات فایل

۱۹.۲ دام‌های رایج

نام ستون را جای تعریف اقتصادی آن نشانیم. `close` در یک منبع ممکن است آخرین معامله باشد، ولی هدف روزانه این پروژه پایانی رسمی است. `close_lag_5` در ساعتی یک نسبت است و در روزانه سطح قیمت. بازده وقفه‌دار با بازده پنج‌دوره‌ای فرق دارد. استانداردسازی هم قیمت را به ریال ثابت یا قدرت خرید واقعی تبدیل نمی‌کند.

۶۰ کندل به معنی ۶۰ ساعت تقویمی نیست. ۴۹ ویژگی به معنی ۴۹ منبع مستقل اطلاعات نیست؛ بسیاری از آن‌ها تبدیل‌های همبسته همان قیمت و حجم‌اند. خروجی استاندارد شده صفر با بازده صفر برابر نیست. «بهترین اعتبارسنجی» هم الزاماً «بهترین آزمون» نمی‌شود.

درصد `MAPE`، درصد سود نیست. باند بولینگر فاصله اطمینان مدل نیست. بازتولید موفق مدل، برتری بر مبنا را ثابت نمی‌کند. `SHA-256` اصالت اقتصادی داده را تضمین نمی‌کند. و کم بودن خطای ساعتی نسبت به روزانه، بدون هدف و افق مشترک، دلیل بهبود روش نیست.

۲۰ پیوست فهرست دقیق ویژگی‌ها

۲۰.۱ ترتیب ویژگی‌های روزانه

جدول زیر ترتیب فایل feature_order.json آزمایش روزانه را حفظ می‌کند. برای فرمول هر گروه به فصل‌های ویژگی و اندیکاتور رجوع کنید. شناسه ترتیب برای بازسازی ماتریس ورودی مهم است.

ردیف	نام ستون	تعریف و تبدیل
۱	adj_open	بازشدن تعدیل‌شده
۲	adj_high	بیشینه تعدیل‌شده
۳	adj_low	کمینه تعدیل‌شده
۴	adj_official_close	پایانی رسمی تعدیل‌شده
۵	volume	حجم سهم خام
۶	return_1	بازده ساده یک مشاهده
۷	close_lag_1	قیمت وقفه ۱ در مقیاس مطلق
۸	return_lag_1	بازده ساده مشاهده ۱ گام قبل
۹	close_lag_2	قیمت وقفه ۲ در مقیاس مطلق
۱۰	return_lag_2	بازده ساده مشاهده ۲ گام قبل
۱۱	close_lag_5	قیمت وقفه ۵ در مقیاس مطلق
۱۲	return_lag_5	بازده ساده مشاهده ۵ گام قبل
۱۳	sma_5	میانگین ساده در ۵ دوره
۱۴	ema_5	میانگین نمایی در ۵ دوره
۱۵	volatility_5	انحراف معیار نمونه‌ای بازده در ۵ دوره
۱۶	rolling_max_5	بیشینه قیمت غلتان در ۵ دوره

ردیف	نام ستون	تعریف و تبدیل
۱۷	rolling_min_5	کمینه قیمت غلتان در ۵ دوره
۱۸	price_to_sma_5	قیمت به میانگین ساده منهای یک در ۵ دوره
۱۹	sma_10	میانگین ساده در ۱۰ دوره
۲۰	ema_10	میانگین نمایی در ۱۰ دوره
۲۱	volatility_10	انحراف معیار نمونه‌ای بازده در ۱۰ دوره
۲۲	rolling_max_10	بیشینه قیمت غلتان در ۱۰ دوره
۲۳	rolling_min_10	کمینه قیمت غلتان در ۱۰ دوره
۲۴	price_to_sma_10	قیمت به میانگین ساده منهای یک در ۱۰ دوره
۲۵	sma_20	میانگین ساده در ۲۰ دوره
۲۶	ema_20	میانگین نمایی در ۲۰ دوره
۲۷	volatility_20	انحراف معیار نمونه‌ای بازده در ۲۰ دوره
۲۸	rolling_max_20	بیشینه قیمت غلتان در ۲۰ دوره
۲۹	rolling_min_20	کمینه قیمت غلتان در ۲۰ دوره
۳۰	price_to_sma_20	قیمت به میانگین ساده منهای یک در ۲۰ دوره
۳۱	rsi_14	قدرت نسبی با هموارسازی وایلدر ۱۴
۳۲	macd	اختلاف EMA ۱۲ و ۲۶

ردیف	نام ستون	تعریف و تبدیل
۳۳	macd_signal	EMA ۹ دوره‌ای مکدی
۳۴	macd_histogram	مکدی منهای خط سیگنال
۳۵	bollinger_upper	میانگین ۲۰ به علاوه دو انحراف معیار قیمت
۳۶	bollinger_lower	میانگین ۲۰ منهای دو انحراف معیار قیمت
۳۷	bollinger_position	فاصله از میانگین تقسیم بر دو انحراف معیار
۳۸	atr_14	میانگین وایلدِر دامنه واقعی ۱۴
۳۹	volume_change	نسبت حجم به حجم قبلی منهای یک
۴۰	relative_volume_20	حجم به میانگین ۲۰ دوره حجم
۴۱	range_to_close	دامنه کندل تقسیم بر قیمت مرجع
۴۲	return_times_volume	بازده ساده ضرب در حجم
۴۳	elapsed_days_feature	فاصله زمانی مشاهده‌ها بر حسب روز
۴۴	weekday_sin	سینوس روز هفته با دوره ۷
۴۵	weekday_cos	کسینوس روز هفته با دوره ۷
۴۶	jalali_month_sin	سینوس ماه شمسی با دوره ۱۲
۴۷	jalali_month_cos	کسینوس ماه شمسی با دوره ۱۲
۴۸	gregorian_month_end	نشانهگر آخرین روز تقویمی ماه میلادی

۲۰.۲ ترتیب ویژگی‌های ساعتی

این جدول ترتیب واقعی ۴۹ ستون آزمایش ساعتی را ثبت می‌کند. در ستون توضیح، تبدیل ساعتی مشخص شده است؛ یک نام مشترک با روزانه الزاماً مقدار مشترک ندارد.

ردیف	نام ستون	تعریف و تبدیل
۱	return_1	بازده ساده یک مشاهده
۲	close_lag_1	قیمت وقفه ۱ تقسیم بر قیمت جاری منهای یک
۳	return_lag_1	بازده ساده مشاهده ۱ گام قبل
۴	close_lag_2	قیمت وقفه ۲ تقسیم بر قیمت جاری منهای یک
۵	return_lag_2	بازده ساده مشاهده ۲ گام قبل
۶	close_lag_5	قیمت وقفه ۵ تقسیم بر قیمت جاری منهای یک
۷	return_lag_5	بازده ساده مشاهده ۵ گام قبل
۸	sma_5	میانگین ساده در ۵ دوره؛ نسبت به قیمت جاری منهای یک
۹	ema_5	میانگین نمایی در ۵ دوره؛ نسبت به قیمت جاری منهای یک
۱۰	volatility_5	انحراف معیار نمونه‌ای بازده در ۵ دوره
۱۱	rolling_max_5	بیشینه قیمت غلتان در ۵ دوره؛ نسبت به قیمت جاری منهای یک
۱۲	rolling_min_5	کمینه قیمت غلتان در ۵ دوره؛ نسبت به قیمت جاری منهای یک
۱۳	price_to_sma_5	قیمت به میانگین ساده منهای یک در ۵ دوره
۱۴	sma_10	میانگین ساده در ۱۰ دوره؛ نسبت به قیمت جاری منهای یک
۱۵	ema_10	میانگین نمایی در ۱۰ دوره؛ نسبت به قیمت جاری منهای یک
۱۶	volatility_10	انحراف معیار نمونه‌ای بازده در ۱۰ دوره
۱۷	rolling_max_10	بیشینه قیمت غلتان در ۱۰ دوره؛ نسبت به قیمت جاری منهای یک

ردیف	نام ستون	تعریف و تبدیل
۱۸	rolling_min_10	کمینه قیمت غلتان در ۱۰ دوره؛ نسبت به قیمت جاری منهای یک
۱۹	price_to_sma_10	قیمت به میانگین ساده منهای یک در ۱۰ دوره
۲۰	sma_20	میانگین ساده در ۲۰ دوره؛ نسبت به قیمت جاری منهای یک
۲۱	ema_20	میانگین نمایی در ۲۰ دوره؛ نسبت به قیمت جاری منهای یک
۲۲	volatility_20	انحراف معیار نمونه‌ای بازده در ۲۰ دوره
۲۳	rolling_max_20	بیشینه قیمت غلتان در ۲۰ دوره؛ نسبت به قیمت جاری منهای یک
۲۴	rolling_min_20	کمینه قیمت غلتان در ۲۰ دوره؛ نسبت به قیمت جاری منهای یک
۲۵	price_to_sma_20	قیمت به میانگین ساده منهای یک در ۲۰ دوره
۲۶	rsi_14	قدرت نسبی با هموارسازی وایلدِر ۱۴
۲۷	macd	اختلاف EMA ۱۲ و ۲۶؛ تقسیم بر قیمت جاری
۲۸	macd_signal	EMA ۹ دوره‌ای مکدی؛ تقسیم بر قیمت جاری
۲۹	macd_histogram	مکدی منهای خط سیگنال؛ تقسیم بر قیمت جاری
۳۰	bollinger_upper	میانگین ۲۰ به علاوه دو انحراف معیار قیمت؛ تقسیم بر قیمت جاری
۳۱	bollinger_lower	میانگین ۲۰ منهای دو انحراف معیار قیمت؛ تقسیم بر قیمت جاری
۳۲	bollinger_position	فاصله از میانگین تقسیم بر دو انحراف معیار
۳۳	atr_14	میانگین وایلدِر دامنه واقعی ۱۴؛ تقسیم بر قیمت جاری

ردیف	نام ستون	تعریف و تبدیل
۳۴	volume_change	نسبت حجم به حجم قبلی منهای یک
۳۵	relative_volume_20	حجم به میانگین ۲۰ دوره حجم
۳۶	range_to_close	دامنه کندل تقسیم بر قیمت مرجع
۳۷	elapsed_days_feature	فاصله زمانی مشاهده‌ها بر حسب روز
۳۸	weekday_sin	سینوس روز هفته با دوره ۷
۳۹	weekday_cos	کسینوس روز هفته با دوره ۷
۴۰	jalali_month_sin	سینوس ماه شمسی با دوره ۱۲
۴۱	jalali_month_cos	کسینوس ماه شمسی با دوره ۱۲
۴۲	gregorian_month_end	نشانگر آخرین روز تقویمی ماه میلادی
۴۳	open_to_last	بازشدن به آخرین قیمت منهای یک
۴۴	high_to_last	بیشینه به آخرین قیمت منهای یک
۴۵	low_to_last	کمینه به آخرین قیمت منهای یک
۴۶	log_volume	لگاریتم یک به‌علاوه حجم سهم
۴۷	hour_sin	سینوس ساعت برچسب با دوره ۲۴
۴۸	hour_cos	کسینوس ساعت برچسب با دوره ۲۴
۴۹	elapsed_hours_feature	فاصله زمانی مشاهده‌ها بر حسب ساعت

۲۱ پیوست نمادها و منابع

۲۱.۱ راهنمای نمادهای ریاضی

نماد	معنی
P_t	قیمت مرجع تعدیل شده در مشاهده هدف
C_s	قیمت پایانی رسمی خام در زنجیره تعدیل
Y_{s+1}	مرجع قبلی گزارش شده در جلسه بعد
O_t, H_t, L_t	بازشدن، بیشینه و کمینه کندل
V_t, A_t	حجم سهم و ارزش معاملات
L, d, N	طول پنجره، شمار ویژگی و شمار نمونه
u	تعداد واحدهای LSTM
h_s, c_s	حالت پنهان و حافظه سلولی
f_s, i_s, o_s	دروازه فراموشی، ورودی و خروجی
$\odot$	ضرب مؤلفه به مؤلفه
μ, s	میانگین و مقیاس استانداردسازی
$\hat{P}_t, e_t$	قیمت پیش بینی شده و خطای دارای علامت

۲۱.۲ منابع داخلی پروژه

تعریف الگوریتم های اجرا شده از فایل های `training.py`، `sequences.py`، `src/marketforecast/features.py` و `hourly.py`، `data.py`، `evaluation.py` و `workflow.py` آمده است. تنظیمات در `configs/default.json` و `configs/hourly.json` قرار دارند. قراردادهای روش در `docs/methodology.md` و توضیح داده شده اند. `docs/hourly_experiment.md`

نتایج روزانه از `feature_order.json`، `model_metadata.json`، `results/foolad_20260926/run/report.md` و `test_metrics.json` خوانده شده اند. نتایج ساعتی از همین فایل ها در `results/foolad-hourly-a100/training-` و `results/hourly-forecast` و از گزارش بررسی محلی آمده اند. یادداشت TSA منبع دامنه مفاهیم مکمل است.

۲۱.۳ منابع بیرونی برای تعریف الگوریتم‌ها

[۱] مستندات رسمی لایه LSTM در Keras

https://keras.io/api/layers/recurrent_layers/lstm/

[۲] مستندات رسمی Adam در Keras

<https://keras.io/api/optimizers/adam/>

[۳] مستندات رسمی StandardScaler

<https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html>

[۴] مستندات رسمی Ridge

https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.Ridge.html

[۵] مقاله اصلی Long Short Term Memory

<https://direct.mit.edu/neco/article/9/8/1735/6109/Long-Short-Term-Memory>

[۶] مقاله Adam A Method for Stochastic Optimization

<https://arxiv.org/abs/1412.6980>

[۷] هولت وینترز در کتاب Forecasting Principles and Practice

<https://otexts.com/fpp3/holt-winters.html>

[۸] فصل مدل‌های ARIMA در همان کتاب

<https://otexts.com/fpp3/arima.html>

برای اختلاف جزئی میان تعریف عمومی و اجرای پروژه، کد و محیط ذخیره شده همان اجرا ملاک‌اند. فرمول‌های این سند قراردادهای پیاده‌سازی را توضیح می‌دهند؛ تحلیل مالی قابل معامله نیازمند داده و ارزیابی مستقلی است که در این دو آزمایش انجام نشده است.